Filière Data Science et Intelligence Artificielle

Module : Séries temporelles

RAPPORT DE MINI-PROJET

Modélisation, prévision et diagnostic d'une série temporelle financière multidimensionnelle

Le cas d'ExxonMobil (XOM) et de l'ETF Energy Select Sector (XLE), 2016-2025

Réalisé par

Aziz Bellaaj

Mohamed Yassine Khiari

Encadré par

M. Ahmed Dhouibi

Année universitaire 2026-2027

Résumé

Ce travail étudie le cours journalier de l'action ExxonMobil (XOM) et de l'ETF sectoriel de l'énergie XLE entre 2016 et 2025, soit 2 514 séances de bourse issues de Yahoo Finance, le prix du Brent servant de variable externe. Il cherche à savoir si le prix de XOM peut être prévu à un horizon de 1 à 10 jours mieux que par une marche aléatoire, et, à défaut, si son risque peut l'être.

Les tests ADF et KPSS concordent pour conclure que les log-prix sont intégrés d'ordre 1. Les rendements se comportent comme un bruit blanc en moyenne mais présentent une forte hétéroscédasticité conditionnelle. Le critère BIC retient la marche aléatoire, ARIMA(0,1,0). Le VAR ne met en évidence aucune prédictibilité croisée robuste et la cointégration entre XOM et XLE n'est acceptée qu'au seuil de 10 % par le test de Johansen. Un modèle GJR-GARCH(1,1) à loi de Student capte l'effet de levier (γ = 0,042, p = 0,004). Les réseaux LSTM et GRU, validés par une procédure walk-forward, ne font pas mieux que la marche aléatoire.

Sur l'année de test (252 origines de prévision, ré-estimation tous les 20 jours), le test de Diebold-Mariano ne désigne aucun modèle significativement meilleur que la marche aléatoire, et les réseaux sont significativement moins précis à 10 jours. Le GJR-GARCH-t est en revanche le seul modèle dont les intervalles de prévision à 95 % ont une couverture correcte (94,8 %, contre environ 98 % pour les modèles à variance constante), avec des intervalles plus étroits de 16 %. Le modèle retenu est donc l'ARIMA(0,1,0) associé à un GJR-GARCH(1,1)-t. Les extensions établissent que la corrélation entre XOM et XLE est dynamique (DCC-GARCH) et que le Brent explique les rendements du jour même sans les prévoir. Un modèle de langage (ChatGPT) a enfin été utilisé et évalué de manière critique.

Le socle de modèles classiques est implémenté en Python et en R, avec une comparaison de 91 grandeurs ; les réseaux de neurones et les extensions sont implémentés en Python uniquement, à l'exception des vérifications en R signalées dans le texte.

Mots-clés : séries temporelles financières, marche aléatoire, ARIMA, VAR, cointégration, VECM, GJR-GARCH, DCC-GARCH, LSTM, GRU, test de Diebold-Mariano.

Abstract

This study examines the daily prices of ExxonMobil (XOM) and of the energy sector ETF XLE from 2016 to 2025 (2,514 trading days from Yahoo Finance), with the Brent crude price as an external variable. It asks whether the XOM price can be forecast 1 to 10 days ahead more accurately than by a random walk and, failing that, whether its risk can be forecast.

ADF and KPSS tests agree that log-prices are integrated of order one. Returns are white noise in the mean but strongly conditionally heteroskedastic. The BIC selects the random walk, ARIMA(0,1,0); the VAR reveals no robust cross-predictability, and cointegration between XOM and XLE is accepted only at the 10 % level by the Johansen test. A GJR-GARCH(1,1) model with Student-t innovations captures the leverage effect (γ = 0.042, p = 0.004). LSTM and GRU networks, validated with a walk-forward scheme, do not outperform the random walk.

Over the test year (252 forecast origins, models re-estimated every 20 days), the Diebold-Mariano test finds no model significantly more accurate than the random walk, and the networks are significantly less accurate at the 10-day horizon. The GJR-GARCH-t, however, is the only model whose 95 % prediction intervals achieve correct coverage (94.8 %, against about 98 % for constant-variance models) while being 16 % narrower. The selected model is therefore ARIMA(0,1,0) with GJR-GARCH(1,1)-t errors. Extensions show that the XOM-XLE correlation is time-varying (DCC-GARCH) and that Brent explains same-day returns without forecasting them. A large language model (ChatGPT) was used and critically assessed.

Keywords: financial time series, random walk, ARIMA, VAR, cointegration, VECM, GJR-GARCH, DCC-GARCH, LSTM, GRU, Diebold-Mariano test.

Table des matières

1. Introduction 6
1.1 Contexte et question de recherche 6
1.2 Démarche et organisation du rapport 6
2. Données et préparation 7
2.1 Source et variables 7
2.2 Valeurs manquantes et calendrier 7
2.3 Découpage chronologique 7
3. Analyse exploratoire 8
3.1 Statistiques descriptives 8
3.2 Autocorrélations 9
3.3 Saisonnalité et valeurs aberrantes 10
3.4 Stationnarité 11
4. Modélisation classique 11
4.1 ARIMA et SARIMA 11
4.2 VAR, causalité au sens de Granger, cointégration et VECM 13
4.3 Volatilité conditionnelle : modèles GARCH 15
4.4 Reproduction en R et comparaison avec Python 16
5. Modélisation avancée : réseaux de neurones récurrents (Python uniquement) 16
5.1 Protocole 16
5.2 Résultats 17
6. Prévision et évaluation hors échantillon 18
6.1 Protocole multi-origines 18
6.2 Tableau récapitulatif 18
6.3 Test de Diebold-Mariano 19
6.4 Intervalles de prévision et prévision de la variance 20
6.5 Comparaison détaillée et choix du modèle 21
7. Extensions 21
7.1 Corrélation dynamique 21
7.2 Le Brent comme variable exogène 22
7.3 Extension non réalisée 23
8. Apport de l'intelligence artificielle générative 23
8.1 Protocole 23
8.2 Résultats de la comparaison 23
8.3 Déclaration relative à l'usage d'outils d'IA 24
9. Discussion et conclusion 24
9.1 Limites des modèles 24
9.2 L'IA générative appliquée aux séries temporelles 25

9.3 Conclusion 25
Références bibliographiques 25
Annexes 28
Annexe A. Reproduction des résultats 28
Annexe B. Interprétation personnelle, rédigée avant l'usage du LLM 29
Annexe C. Prompts et réponses intégrales du LLM 31
Annexe D. Comparaison détaillée entre notre interprétation et celle du LLM 50

1. Introduction

1.1 Contexte et question de recherche

La prévision des cours boursiers occupe une place particulière en économétrie financière. Selon l'hypothèse d'efficience des marchés sous sa forme faible (Fama, 1970), les prix passés ne contiennent aucune information permettant de prévoir les rendements futurs, si bien que la marche aléatoire constitue une référence difficile à battre. Cette hypothèse ne s'applique pas à la variance : depuis les travaux d'Engle (1982) et de Bollerslev (1986), il est établi que la volatilité des rendements financiers est persistante et donc en partie prévisible.

Ce projet confronte ces deux résultats à une série concrète, en mobilisant l'ensemble des outils du cours, des modèles de Box et Jenkins (1976) aux réseaux de neurones récurrents (Hochreiter et Schmidhuber, 1997 ; Cho et al., 2014). Nous avons retenu l'option finance du cahier des charges. La série principale est le cours ajusté d'ExxonMobil (XOM), première capitalisation pétrolière américaine. Elle est étudiée conjointement avec l'ETF Energy Select Sector SPDR (XLE), dont XOM est le premier composant (environ un quart de l'ETF en 2026), et avec le contrat à terme sur le Brent (BZ=F) comme variable externe. Ce couple formé d'une action et de son secteur se prête à toute la chaîne de modélisation : deux séries intégrées pour l'étude de la cointégration, des rendements à effets ARCH pour le GARCH, un lien contemporain fort pour le VAR et pour l'étude de la corrélation dynamique.

La question de recherche est la suivante : un investisseur peut-il prévoir le prix de XOM à 1, 5 et 10 jours mieux qu'en supposant que le prix de demain sera celui d'aujourd'hui ? À défaut, peut-il prévoir l'amplitude des variations, c'est-à-dire le risque ?

1.2 Démarche et organisation du rapport

La démarche suit l'ordre du cahier des charges. La section 2 présente les données et leur préparation, la section 3 l'analyse exploratoire, la section 4 les modèles économétriques classiques et la section 5 les réseaux de neurones. La section 6 évalue tous les modèles hors échantillon selon un protocole commun. La section 7 présente deux extensions, la section 8 l'usage critique d'un modèle de langage, et la section 9 discute les limites du travail avant de conclure.

Le tableau 1 recense les livrables. Toutes les valeurs citées dans ce rapport proviennent d'une exécution réelle du code ; la graine aléatoire est fixée à 42 et les versions des bibliothèques sont figées.

Tableau 1. Livrables du projet.

Livrable	Contenu
notebooks/main_python.ipynb	Étude complète, exécutable de bout en bout sans intervention
notebooks/classical_R.Rmd et son rendu HTML	Socle classique en R, comparaison avec Python, vérification du test de Diebold-Mariano et du DCC
src/*.py	Code Python : données, analyse exploratoire, modèles classiques, réseaux, évaluation, extensions
llm/	Interprétation personnelle, prompts et réponses intégrales du modèle de langage, comparaison
docs/journal.md, docs/sources.md	Résultats et décisions par étape ; sources des faits externes

2. Données et préparation

2.1 Source et variables

Les cours journaliers sont extraits de Yahoo Finance à l'aide de la bibliothèque *yfinance*, du 1er janvier 2016 au 31 décembre 2025. Nous utilisons la colonne *Adj Close*, ajustée des dividendes et des divisions d'actions. L'écart avec le cours de clôture brut est important : au 4 janvier 2016, le cours de clôture de XOM vaut 77,46 $ et son cours ajusté 49,00 $. Sans cet ajustement, chaque détachement de dividende produirait une baisse fictive du prix.

Yahoo Finance recalcule le cours ajusté à chaque nouveau dividende. Afin de garantir la reproductibilité des résultats, les données téléchargées le 8 novembre 2026 ont été figées dans un fichier de cache versionné (data/raw/), relu en priorité par les codes Python et R. Le tableau 2 définit les variables dérivées.

Tableau 2. Variables utilisées.

Variable	Définition	Usage
Prix ajusté P_t	Adj Close	Métriques d'évaluation, en dollars
Log-prix	$\ln P_t$	Stationnarité, cointégration
Rendement r_t	$100 \times \Delta \ln P_t$, en %	Variable modélisée (ARIMA, VAR, GARCH, réseaux)
Volatilité réalisée	Écart-type des rendements sur 21 jours, multiplié par $\sqrt{252}$	Indicateur de risque, entrée des réseaux
Moyenne mobile	50 jours	Indicateur technique, graphiques

Toutes les fenêtres glissantes ne portent que sur le passé, de sorte qu'aucune information de l'échantillon de test ne peut se diffuser vers l'échantillon d'apprentissage.

2.2 Valeurs manquantes et calendrier

XOM et XLE partagent exactement le même calendrier : 2 514 séances, sans valeur manquante ni doublon. Le Brent, coté sur un autre marché, manque deux jours du calendrier commun (10 octobre et 11 novembre 2016), et trois cotations hors calendrier ont été écartées.

Nous n'avons procédé à aucune imputation. Reporter la valeur de la veille créerait des rendements nuls fictifs qui biaiseraient à la baisse l'estimation de la variance conditionnelle. Les modèles reçoivent donc un index positionnel, c'est-à-dire la suite des séances, et les dates ne servent qu'aux représentations graphiques.

2.3 Découpage chronologique

L'échantillon est découpé chronologiquement, sans mélange des observations (tableau 3). Toute l'identification des modèles, qu'il s'agisse des tests, du choix des ordres ou des hyperparamètres, est réalisée sur l'échantillon d'apprentissage.

Tableau 3. Découpage de l'échantillon.

Échantillon	Séances	Période
Apprentissage (90 %)	2 262	du 4 janvier 2016 au 27 décembre 2024
Test (10 %)	252	du 30 décembre 2024 au 31 décembre 2025

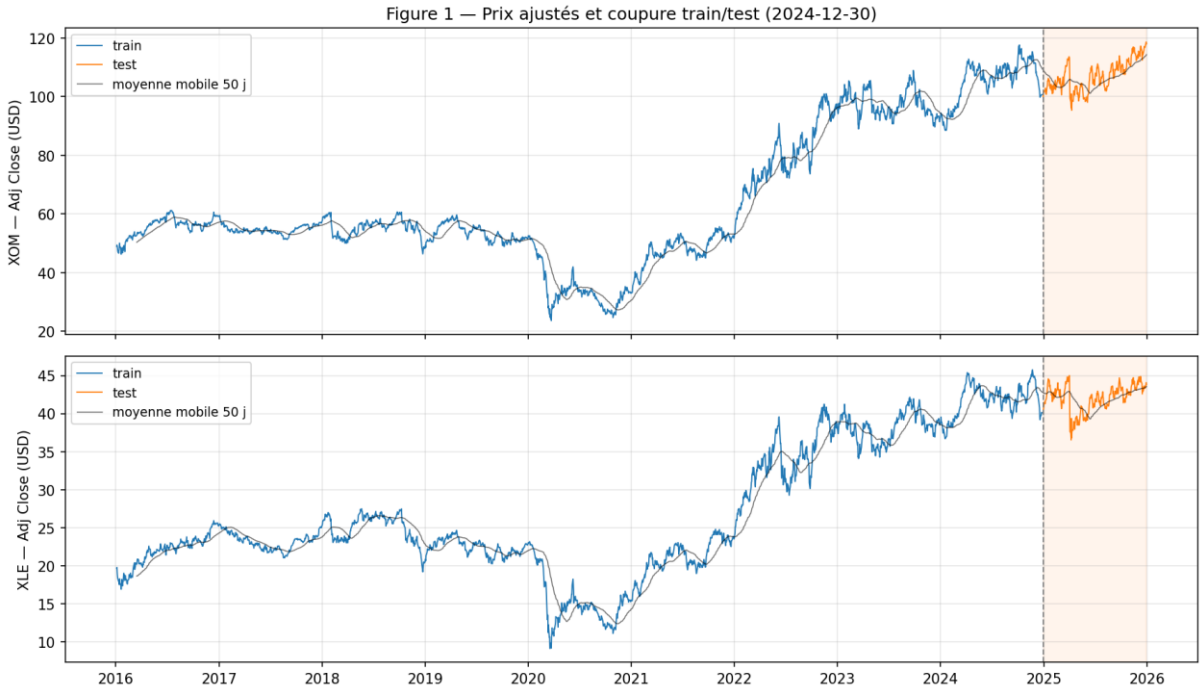


Figure 1. Prix ajustés de XOM et de XLE et séparation entre apprentissage et test (figure 1 du notebook).

Les deux prix évoluent de concert sur toute la période : effondrement de 2020, forte hausse en 2021 et 2022, puis plateau. La figure 1 montre aussi que la période de test est plus calme que la période d'apprentissage. La volatilité réalisée de XOM y atteint au plus 47,4 %, contre 108,9 % pendant l'apprentissage. Les métriques calculées sur le test reflètent ce régime, ce dont il faudra tenir compte dans la section 6.

3. Analyse exploratoire

L'ensemble de cette section porte sur l'échantillon d'apprentissage.

3.1 Statistiques descriptives

Tableau 4. Statistiques descriptives des rendements journaliers.

Rendements (%)	Moyenne	Écart-type	Volatilité annualisée	Asymétrie	Excès de kurtosis	Jarque-Bera
XOM	0,032	1,78	28,3 %	−0,16	6,6	4 142 (p < 0,0001)
XLE	0,031	1,92	30,5 %	−0,89	16,4	25 747 (p < 0,0001)

La moyenne des rendements n'est pas significativement différente de zéro. Pour XOM, le test de Student avec erreurs-types robustes de Newey et West (1987), calculées avec 7 retards, donne t = 0,86 et p = 0,39 : l'hypothèse d'une espérance nulle n'est pas rejetée, et le modèle de la moyenne peut se passer de constante.

La normalité est en revanche nettement rejetée par le test de Jarque et Bera (1980), en raison de queues épaisses (excès de kurtosis de 6,6 et 16,4) et d'une asymétrie négative. Ce constat justifie deux choix ultérieurs : l'emploi d'une loi de Student pour le GARCH, et le recours au test de Jarque-Bera plutôt qu'à celui de Shapiro-Wilk, qui rejette presque systématiquement la normalité sur un échantillon de 2 000 observations.

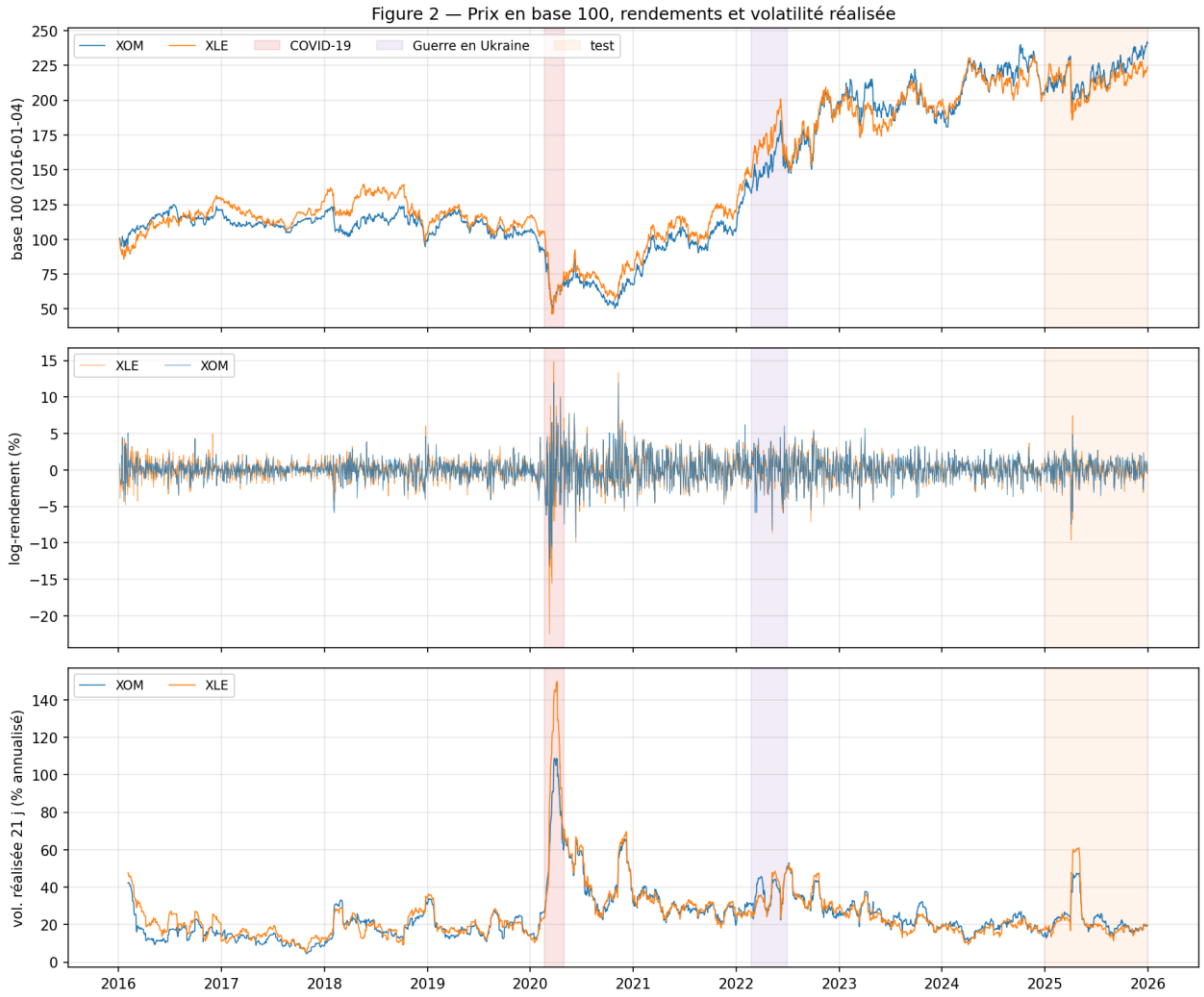


Figure 2. Prix, rendements journaliers et volatilité réalisée sur 21 jours, 2016-2025 (figure 2 du notebook).

Les rendements oscillent autour de zéro, mais leur amplitude varie fortement dans le temps (figure 2). Des périodes calmes alternent avec des grappes de fortes variations, au début de 2016, en mars et avril 2020, en 2022 et en avril 2025. Ce regroupement des fortes variations est caractéristique de l'hétéroscédasticité conditionnelle que modélise le GARCH.

3.2 Autocorrélations

Le log-prix présente une autocorrélation d'ordre 1 de 0,998 et une décroissance très lente (les 40 premiers retards sont significatifs), avec un seul pic d'autocorrélation partielle au retard 1. C'est le profil typique d'une marche aléatoire. Les autocorrélations des rendements sont au contraire très faibles (au plus 0,064 en valeur absolue pour XOM), tandis que celles des rendements au carré sont significatives aux 40 retards, avec un maximum de 0,32.

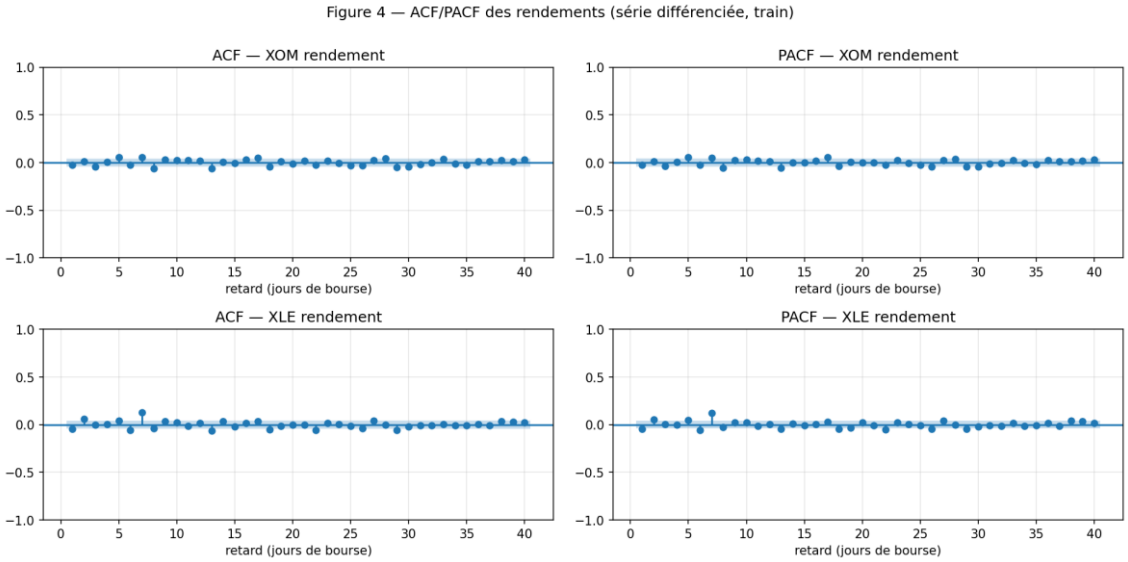


Figure 3. Fonctions d'autocorrélation et d'autocorrélation partielle des rendements de XOM (en haut) et de XLE (en bas) sur l'apprentissage (figure 4 du notebook ; rendements au carré : figure 5).

Le test de Ljung et Box (1978), dont l'hypothèse nulle est l'absence d'autocorrélation jusqu'au retard 10, précise ce diagnostic (tableau 5).

Tableau 5. Test de Ljung-Box sur les rendements de XOM.

Rendements de XOM	**Q(10) et p-value**	**Décision**
Bruts	34,9 ; p = 0,0001	H_0 rejetée
Standardisés par la volatilité des 21 jours précédents	p = 0,98	H_0 non rejetée
Hors année 2020	p = 0,44	H_0 non rejetée
Au carré	1 464 ; p < 0,0001	H_0 rejetée

Le rejet observé sur les rendements bruts disparaît dès que l'on neutralise la volatilité ou que l'on exclut l'année 2020. Il s'agit donc d'un artefact de l'hétéroscédasticité et non d'une véritable dynamique de la moyenne. Les rendements se comportent comme un bruit blanc en moyenne, alors que leur variance, mesurée par les rendements au carré, est fortement prévisible.

3.3 Saisonnalité et valeurs aberrantes

La décomposition STL (Cleveland et al., 1990) ne révèle aucune saisonnalité : la force saisonnière vaut 0,000 pour une période de 5 jours comme pour une période de 252 jours, et 0,032 pour une période de 21 jours. Le test de Kruskal et Wallis (1952) ne rejette pas l'égalité des distributions des rendements selon le jour de la semaine (p = 0,59).

Les valeurs aberrantes sont détectées par un critère interquartile glissant calculé sur les 63 séances précédentes (k = 3). On en dénombre 15 pour XOM et 18 pour XLE, dont 10 en 2020 pour chacune des deux séries. Elles ont été conservées : il s'agit de chocs réels, communs aux deux actifs, que le GARCH a précisément vocation à modéliser. Une variable indicatrice les signale. Cette détection est robuste, puisqu'un noyau de 11 jours est retrouvé pour XOM par au moins 12 des 16 réglages testés.

3.4 Stationnarité

Les tests de Dickey et Fuller augmenté (ADF ; Dickey et Fuller, 1979) et de Kwiatkowski, Phillips, Schmidt et Shin (KPSS ; 1992) reposent sur des hypothèses nulles opposées : la présence d'une racine unitaire pour le premier, la stationnarité pour le second. Une conclusion n'est retenue que lorsque les deux tests concordent. Les retards de l'ADF sont choisis par le critère AIC ; les valeurs critiques à 5 % sont −2,86 (avec constante) et −3,41 (avec constante et tendance) pour l'ADF, 0,463 et 0,146 pour le KPSS.

Tableau 6. Tests de stationnarité ADF et KPSS (échantillon d'apprentissage).

Série	Spécification	ADF : statistique (retards), p	KPSS : statistique (retards), p	Conclusion
Log-prix XOM	constante	−0,971 (18), p = 0,76	3,563 (29), p < 0,01	non stationnaire
Log-prix XOM	constante et tendance	−1,600 (18), p = 0,79	1,397 (29), p < 0,01	non stationnaire
Rendements XOM	constante	−10,557 (17), p < 0,001	0,144 (8), p > 0,10	stationnaire
Log-prix XLE	constante	−1,503 (7), p = 0,53	3,586 (29), p < 0,01	non stationnaire
Rendements XLE	constante	−16,064 (6), p < 0,001	0,084 (9), p > 0,10	stationnaire

Une rupture structurelle peut conduire à tort à accepter une racine unitaire. Le test de Zivot et Andrews (1992), qui autorise une rupture de date inconnue, ne rejette pas non plus l'hypothèse de racine unitaire (p compris entre 0,18 et 0,48), les ruptures étant estimées en janvier 2020 et en décembre 2021.

Les log-prix sont donc intégrés d'ordre 1 et les rendements stationnaires, ce qui conduit à retenir d = 1 et D = 0. Les modèles portent sur les rendements et non sur les prix.

4. Modélisation classique

Les modèles de cette section sont estimés en Python et reproduits en R (section 4.4).

4.1 ARIMA et SARIMA

Un modèle ARIMA(p,1,q) du log-prix est estimé sous la forme d'un ARMA(p,q) des rendements :

$$\phi(L)\, r_t = c + \theta(L)\, \varepsilon_t,$$

où L est l'opérateur retard, ϕ et θ des polynômes de degrés p et q, et la constante c représente la dérive du prix. Cette convention garantit que tous les modèles portent sur les mêmes 2 261 observations, ce qui rend leurs critères d'information comparables. Les erreurs-types sont robustes, de type sandwich (quasi-maximum de vraisemblance), afin de tenir compte des effets ARCH qui rendraient les erreurs-types usuelles trop optimistes.

Tableau 7. Modèles ARIMA candidats (échantillon d'apprentissage).

Modèle	AIC	BIC	Coefficients (p-value robuste)
ARIMA(0,1,0)	9 037,10	9 042,83	aucun
ARIMA(1,1,0)	9 037,84	9 049,29	AR(1) = −0,024 (p = 0,49)
ARIMA(0,1,1)	9 037,87	9 049,32	MA(1) = −0,023 (p = 0,50)
ARIMA(0,1,0) avec dérive	9 038,38	9 049,83	dérive = 0,032 (p = 0,40)
ARIMA(3,1,2), recherche automatique	9 021,27	9 055,6	racines AR et MA quasi identiques

Modèle	AIC	BIC	Coefficients (p-value robuste)
(AIC)			

L'identification manuelle selon la méthode de Box et Jenkins ne fait apparaître aucun pic net dans les fonctions d'autocorrélation des rendements. Les candidats de petit ordre ont tous des coefficients non significatifs, et la marche aléatoire obtient à la fois le meilleur AIC et le meilleur BIC (tableau 7).

La recherche automatique exhaustive (*pmdarima*, p et q au plus égaux à 5) retient un ARIMA(3,1,2) selon l'AIC, avec un gain de 15,8 points, mais l'ARIMA(0,1,0) selon le BIC. L'ARIMA(3,1,2) présente plusieurs signes de surajustement. Ses racines autorégressives (module 1,047) et de moyenne mobile (module 1,075) se compensent presque, ses résidus standardisés restent autocorrélés (Ljung-Box, p = 0,013), et son gain d'AIC devient une perte de 9,2 points lorsque le modèle est estimé sur des rendements standardisés. En R, l'optimiseur converge en outre vers un autre maximum local de la vraisemblance (section 4.4).

Le modèle SARIMA de période 5 améliore l'AIC de 5,7 points et le test du rapport de vraisemblance lui est favorable (p = 0,006). Son coefficient saisonnier n'est cependant pas significatif avec des erreurs-types robustes (0,058, p = 0,12), le BIC est pratiquement inchangé (+0,05) et le gain disparaît lorsque l'on exclut 2020. Compte tenu d'une force saisonnière nulle, le SARIMA a été écarté.

Les résidus de la marche aléatoire ont été soumis aux trois tests de diagnostic. Le test de Ljung-Box sur les résidus standardisés ne rejette pas l'absence d'autocorrélation (p = 0,98). Le test de Jarque-Bera rejette la normalité (4 142). Enfin, le test ARCH-LM d'Engle (1982) à 5 retards, dont l'hypothèse nulle est l'absence d'effet ARCH, la rejette nettement (441, p < 0,0001).

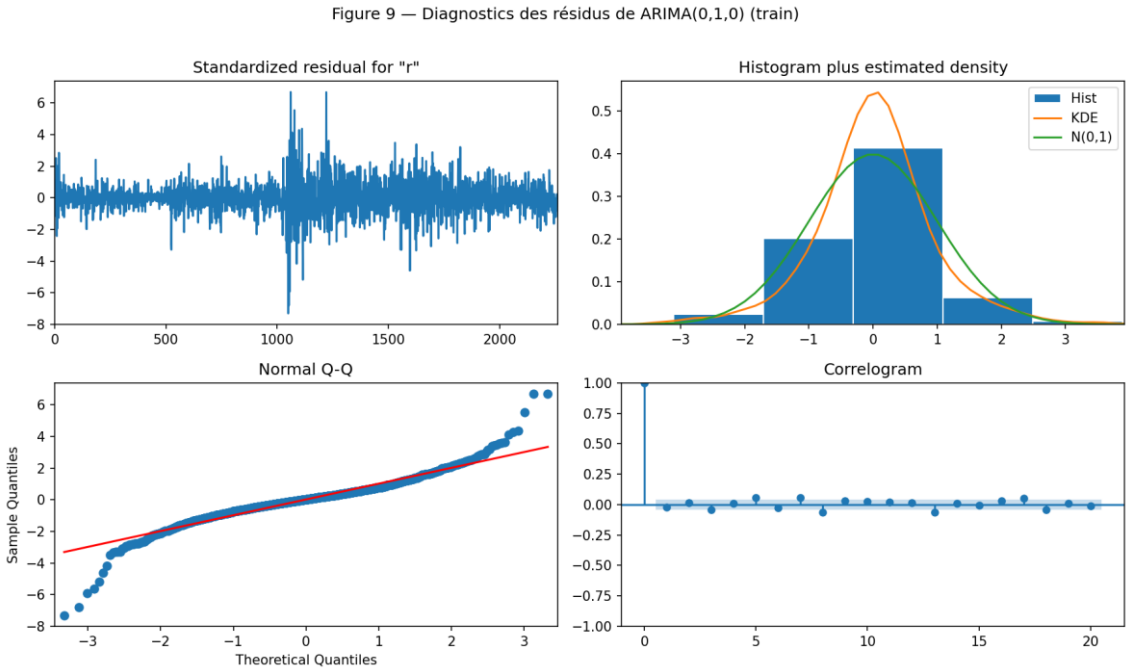


Figure 4. Diagnostic des résidus de l'ARIMA(0,1,0) : série, histogramme, diagramme quantile-quantile et autocorrélations (figure 9 du notebook).

Nous retenons donc l'ARIMA(0,1,0) sans dérive, c'est-à-dire la marche aléatoire. Ce modèle décrit correctement la moyenne mais pas la variance, qui appelle une modélisation GARCH (section 4.3). L'ARIMA(3,1,2) est conservé comme modèle concurrent pour l'évaluation hors échantillon.

4.2 VAR, causalité au sens de Granger, cointégration et VECM

Modèle VAR des rendements

Le vecteur $\boldsymbol{r}_t$ des rendements de XOM et de XLE est modélisé par un VAR(p) (Sims, 1980) :

$$\boldsymbol{r}_t = \boldsymbol{c} + \sum_{i=1}^{p} A_i \, \boldsymbol{r}_{t-i} + \boldsymbol{u}_t.$$

Le critère AIC retient 9 retards et le BIC aucun. Hors 2020 et sur rendements standardisés, les quatre critères d'information retiennent 0 retard, ce qui montre que l'ordre élevé choisi par l'AIC est induit par l'année 2020. Le test portmanteau multivarié de Hosking (1980), appliqué aux résidus standardisés, confirme ce choix : p = 0,77 pour le VAR(0), 0,038 pour le VAR(1), et p < 0,0001 pour le VAR(7) et le VAR(9). L'ajout de retards introduit donc une structure parasite. La corrélation entre les résidus des deux équations atteint 0,915, ce qui indique un lien essentiellement contemporain entre XOM et XLE.

Causalité au sens de Granger

Le test de Granger (1969) a pour hypothèse nulle que le passé de XLE n'améliore pas la prévision de XOM. Le test F usuel la rejette (p = 0,009), mais il ne la rejette plus lorsque l'on utilise des erreurs-types robustes à l'hétéroscédasticité de type HC3 (MacKinnon et White, 1985), avec p = 0,20. Hors 2020, aucun test robuste ne la rejette au seuil de 5 %. Il n'existe donc pas de prédictibilité croisée robuste. Rappelons que ce test mesure une prédictibilité incrémentale et non une causalité au sens strict.

Réponses impulsionnelles et décomposition de la variance

Un choc d'un écart-type sur XLE fait varier XOM de +1,63 % le jour même et de −0,08 % le lendemain ; l'effet est ensuite nul, quel que soit l'ordre de la décomposition de Cholesky (figure 5). La décomposition de la variance des erreurs de prévision (FEVD) attribue 83,7 % de la variance de XOM à XLE lorsque XLE est placé en premier, mais seulement 0,3 % lorsque XOM est placé en premier. La valeur de 83,7 % est exactement égale au carré de la corrélation des résidus ($0{,}915^2$) : la FEVD se borne ici à attribuer la covariance contemporaine à la variable placée en premier. Sans restrictions d'identification supplémentaires, comme celles d'un VAR structurel, il n'est donc pas possible de déterminer laquelle des deux séries entraîne l'autre.

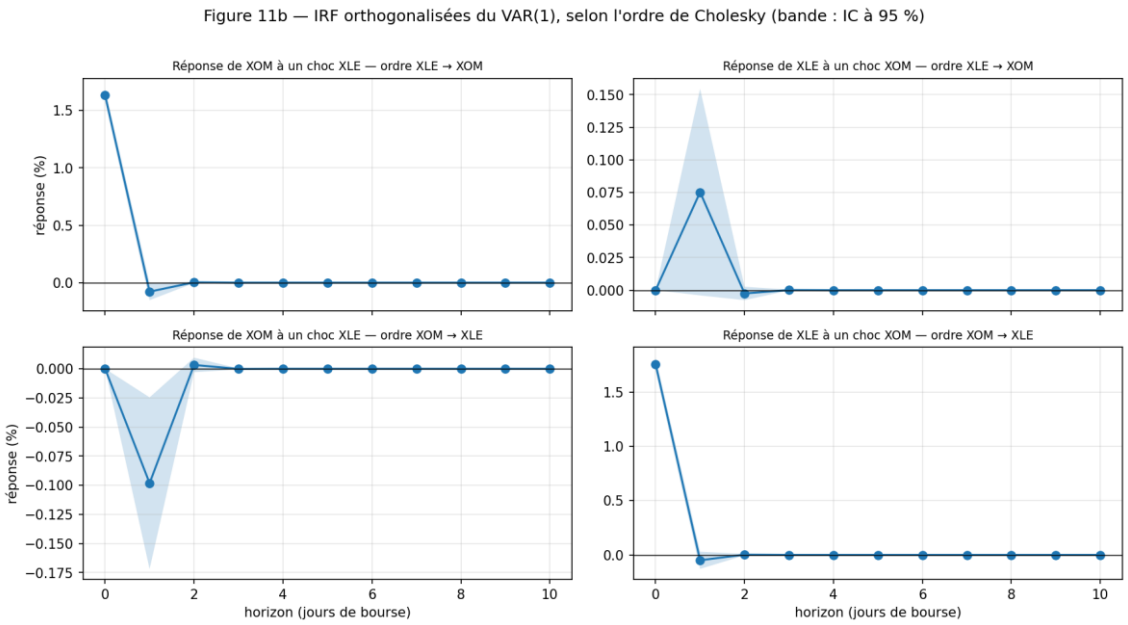


Figure 5. Réponses impulsionnelles orthogonalisées du VAR(1) pour les deux ordres de Cholesky ; la bande représente l'intervalle de confiance à 95 % (figure 11b du notebook).

Cointégration des log-prix

Les log-prix de XOM et de XLE étant tous deux intégrés d'ordre 1, nous avons testé l'existence d'une relation de long terme par les méthodes d'Engle et Granger (1987) et de Johansen (1991). Le tableau 8 résume les résultats.

Tableau 8. Tests de cointégration des log-prix de XOM et de XLE.

Test	H_0	Statistique	p-value ou seuil	Décision
Engle-Granger (constante)	absence de cointégration		p = 0,037	rejet à 5 %
Engle-Granger (constante et tendance)	absence de cointégration		p = 0,105	non-rejet
Johansen, trace (r = 0)	aucune relation	14,73	VC à 10 % = 13,43 ; VC à 5 % = 15,49	rejet à 10 % seulement
Engle-Granger, 2016-2019 et 2021-2024	absence de cointégration		p = 0,081 et 0,232	non-rejet

La cointégration apparaît faible et fragile. Elle n'est acceptée qu'au seuil de 10 % par le test de Johansen, dépend de la spécification retenue et disparaît dans chacune des sous-périodes. Le VECM est néanmoins estimé à titre conditionnel, avec un rang de cointégration égal à 1 et une constante dans la relation de long terme :

$$\Delta \boldsymbol{y}_t = \boldsymbol{\alpha}(\boldsymbol{\beta}' \boldsymbol{y}_{t-1} + \mu) + \boldsymbol{u}_t,$$

où $\boldsymbol{y}_t$ est le vecteur des log-prix. On obtient β = (1 ; −1,128), soit à long terme ln XOM ≈ 1,128 ln XLE + 0,453. Les coefficients d'ajustement ont le signe attendu mais ne sont pas significatifs (α_{XOM} = −0,0006, p = 0,93 ; α_{XLE} = +0,0093, p = 0,16). La demi-vie d'un écart à l'équilibre, égale à ln(0,5)/ln(1 + β'α), est de 62,6 séances : en 10 jours, la correction ne résorbe qu'environ 10 % d'un écart.

4.3 Volatilité conditionnelle : modèles GARCH

Sur les résidus de la marche aléatoire, la statistique ARCH-LM à 5 retards vaut 441,2 ($p < 0{,}0001$), ce qui confirme que la variance conditionnelle n'est pas constante. Nous avons comparé quatre structures, GARCH(1,1), GJR(1,1), GARCH(1,2) et GARCH(2,1), combinées à trois lois pour les innovations (normale, Student, Student asymétrique), avec une moyenne nulle. La loi de Student (Bollerslev, 1987) améliore la log-vraisemblance d'environ 37 points par rapport à la loi normale, tandis que la loi asymétrique et les ordres supérieurs n'apportent aucun gain. Le modèle GJR(1,1) de Glosten, Jagannathan et Runkle (1993) avec innovations de Student obtient le meilleur AIC et le meilleur BIC. Il s'écrit :

$$r_t = \varepsilon_t = \sigma_t z_t, \qquad \sigma_t^2 = \omega + \left(\alpha + \gamma\, \mathbb{1}_{\{\varepsilon_{t-1}<0\}}\right)\varepsilon_{t-1}^2 + \beta\, \sigma_{t-1}^2,$$

où z_t suit une loi de Student standardisée à ν degrés de liberté. Le tableau 9 donne les estimations, avec les erreurs-types robustes de Bollerslev et Wooldridge (1992).

Tableau 9. Estimation du GJR-GARCH(1,1) à loi de Student (échantillon d'apprentissage).

Paramètre	Estimation	p-value	Interprétation
ω	0,0094	0,066	constante de la variance
α	0,043	< 0,001	réaction aux chocs
γ	0,042	0,004	réaction supplémentaire aux chocs négatifs (levier)
β	0,935	< 0,001	persistance de la variance
ν	7,47	< 0,001	degrés de liberté (queues épaisses)

L'hypothèse nulle d'absence d'effet de levier ($\gamma = 0$) est rejetée ($p = 0{,}004$). Une baisse accroît la variance du lendemain de $\alpha + \gamma = 0{,}085$, contre $\alpha = 0{,}043$ pour une hausse de même ampleur, soit un effet environ deux fois plus fort.

La persistance, mesurée par $\alpha + \beta + \gamma/2$, vaut 0,9993 sur l'apprentissage. Elle reste inférieure à 1, de sorte que la condition de stationnarité est respectée, mais de justesse. Cette valeur est gonflée par la rupture de 2020 : elle n'est que de 0,893 sur 2016-2019, soit une demi-vie de 6 jours, contre 0,996 sur 2021-2024. Lamoureux et Lastrapes (1990) ont montré qu'un GARCH tend à confondre un changement de niveau de la volatilité avec une forte persistance.

Les résidus standardisés ne présentent plus d'autocorrélation (Ljung-Box sur z_t, $p = 0{,}97$). La statistique ARCH-LM à 5 retards passe de 441 à 14,0, soit une baisse de 97 %, mais demeure significative ($p = 0{,}016$). Le test de Kolmogorov-Smirnov ne rejette pas l'adéquation à la loi de Student estimée ($p = 0{,}46$). Le modèle capte donc l'essentiel de l'hétéroscédasticité, sans l'éliminer entièrement.

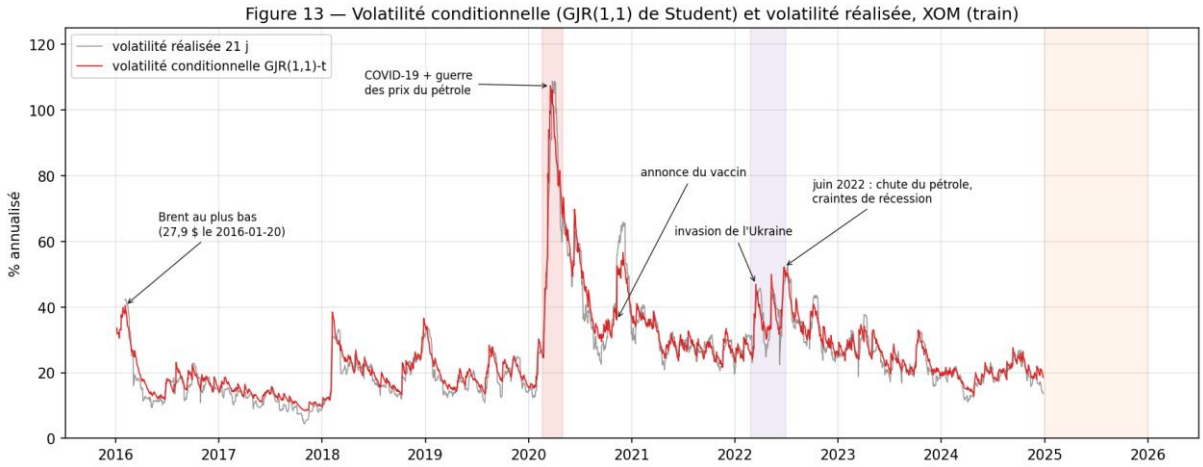


Figure 6. Volatilité conditionnelle annualisée estimée par le GJR-GARCH-t et événements documentés (figure 13 du notebook).

La volatilité estimée suit de près la volatilité réalisée, avec une corrélation de 0,97 (figure 6). Ses pics coïncident avec des événements documentés : 107,4 % le 19 mars 2020 (guerre des prix au sein de l'OPEP+ et pandémie de COVID-19), 46,9 % le 16 mars 2022 (invasion de l'Ukraine) et 52,2 % le 24 juin 2022 (chute des valeurs du secteur de l'énergie). Il convient de souligner qu'un GARCH prévoit l'amplitude des variations et non leur sens.

4.4 Reproduction en R et comparaison avec Python

Le socle classique, de la préparation des données au GARCH, est reproduit en R dans le document classical_R.Rmd à l'aide des bibliothèques *quantmod*, *forecast*, *urca*, *vars* et *rugarch*, à partir du même cache de données. Sur les 91 grandeurs comparées, 71 sont identiques (écart inférieur à 0,1 %), 14 sont très proches (écart inférieur à 2 %) et 6 diffèrent davantage. Aucune conclusion n'en est modifiée.

Chacun de ces écarts a une cause identifiée, vérifiée en imposant le même réglage dans les deux langages : l'échantillon utilisé pour choisir les retards de l'ADF et du test d'Engle-Granger, le point de départ de l'optimiseur de l'ARIMA(3,1,2), les ordres examinés par la fonction VARselect (qui n'examine pas l'ordre 0) et la variance initiale du GARCH. Deux de ces écarts sont instructifs : la vraisemblance de l'ARIMA(3,1,2) présente plusieurs maxima, ce qui rend son choix par l'AIC instable, et le test d'Engle-Granger est sensible aux toutes premières observations, ce qui confirme la fragilité de la cointégration.

5. Modélisation avancée : réseaux de neurones récurrents (Python uniquement)

5.1 Protocole

Les réseaux prévoient directement les 10 rendements suivants de XOM, en une seule sortie, et le prix est ensuite reconstruit par

$$\hat{P}_{t+h} = P_t \exp\left(\frac{1}{100}\sum_{j=1}^{h}\hat{r}_{t+j}\right).$$

Aucun réseau n'est entraîné sur les prix bruts, qui ne sont pas stationnaires. Les entrées sont des fenêtres glissantes de 20 ou 60 jours portant sur trois variables : les rendements de XOM et de XLE et la volatilité réalisée de XOM.

La validation repose sur un découpage walk-forward en 5 blocs à fenêtre croissante sur l'apprentissage (TimeSeriesSplit), avec un intervalle de 10 jours entre la partie d'ajustement et la partie d'évaluation pour éviter le chevauchement des cibles. La validation croisée classique par k blocs est exclue. La normalisation est ajustée sur la partie d'ajustement de chaque bloc. L'arrêt précoce (patience de 10 époques) est fondé sur les 10 % finaux de cette partie, avec restauration des meilleurs poids, et chaque configuration est entraînée avec trois graines (42, 43 et 44).

La grille d'hyperparamètres croise les deux architectures, LSTM et GRU, avec deux tailles de fenêtre (20 et 60), deux nombres d'unités (32 et 64) et deux taux de dropout (0,2 et 0,4), soit 16 configurations et 80 entraînements. Le critère de sélection est le gain moyen par rapport à la prévision nulle, calculé sur les mêmes échantillons, car le RMSE brut n'est pas comparable d'une taille de fenêtre à l'autre.

5.2 Résultats

Les 16 configurations sont toutes moins précises que la marche aléatoire, avec un gain moyen compris entre −0,14 % et −0,43 %. Les configurations retenues sont un LSTM (fenêtre de 20 jours, 64 unités, dropout de 0,2) et un GRU (fenêtre de 20 jours, 32 unités, dropout de 0,4). Le tableau 10 compare leurs performances en validation.

Tableau 10. Performances en validation walk-forward.

Modèle	RMSE moyen sur les 5 blocs (rendements, %)
Marche aléatoire (prévision nulle)	1,8450
Moyenne de l'apprentissage	1,8457
LSTM	1,8472
GRU	1,8482
ARIMA(3,1,2)	1,8501
Hybride ARIMA(3,1,2) et LSTM	1,8527

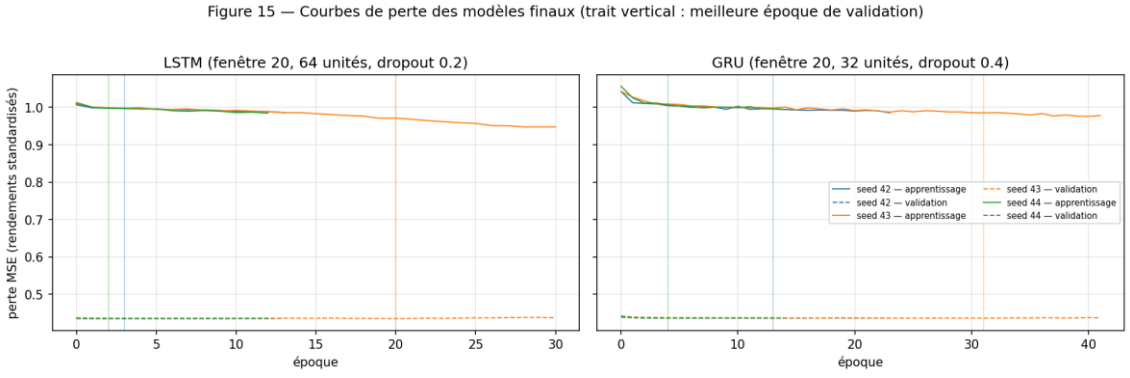


Figure 7. Courbes de perte des modèles LSTM et GRU retenus, pour les trois graines (figure 15 du notebook).

La perte de validation est plate dès la première époque (de 0,4348 à 0,4343 au mieux pour le LSTM), ce qui montre que le réseau n'apprend aucune structure généralisable (figure 7). Ses prévisions sont presque constantes, avec un écart-type de 0,058 % contre 1,297 % pour les rendements observés, et leur corrélation avec les rendements réalisés n'est que de 0,016. Le réseau retrouve ainsi, de fait, la marche aléatoire. Le changement de graine modifie la prévision d'un montant comparable à son amplitude, raison pour laquelle nous utilisons la moyenne des trois graines.

Nous avons également estimé un modèle hybride dans l'esprit de Zhang (2003) : l'ARIMA(3,1,2) modélise la partie linéaire et un LSTM ses résidus. Ce modèle ne bat la marche aléatoire sur aucun bloc et fait moins bien que l'ARIMA seul sur 3 blocs sur 5, ce qui indique que les résidus ne contiennent pas de structure non linéaire exploitable dans la moyenne.

Ce résultat confirme, avec une classe de modèles non linéaires, l'absence de structure exploitable dans la moyenne des rendements. Le modèle Prophet n'a pas été estimé, faute de saisonnalité à modéliser.

6. Prévision et évaluation hors échantillon

6.1 Protocole multi-origines

À chacune des 252 origines de l'échantillon de test, du 27 décembre 2024 au 30 décembre 2025, chaque modèle prévoit le prix de XOM aux horizons h = 1 à 10 en n'utilisant que l'information disponible à cette date. Les modèles classiques sont ré-estimés tous les 20 jours, soit 13 estimations, et leur état est mis à jour quotidiennement ; les réseaux sont entraînés une seule fois sur l'apprentissage. On dispose ainsi de 243 à 252 erreurs de prévision par horizon, nombre nécessaire au test de Diebold-Mariano. Les prévisions calculées par notre code ont été vérifiées identiques à celles de *statsmodels*.

6.2 Tableau récapitulatif

Le tableau 11 rassemble les métriques de précision calculées sur le prix en dollars. La MSE, carré du RMSE, figure dans le tableau complet fourni avec le code (outputs/tables/tab36_metriques_prix.csv). La MAPE n'est jamais calculée sur les rendements, dont les valeurs proches de zéro rendraient l'erreur relative instable.

Tableau 11. Précision des prévisions du prix de XOM sur l'échantillon de test (en dollars).

Modèle	RMSE h=1	MAE h=1	MAPE h=1	RMSE h=5	MAE h=5	RMSE h=10	MAE h=10	MAPE h=10
Marche aléatoire	1,560	1,170	1,10 %	3,617	2,762	4,650	3,487	3,29 %
ARIMA(3,1,2)	1,569	1,175	1,11 %	3,620	2,764	4,657	3,495	3,29 %
VAR(1)	1,561	1,166	1,10 %	3,616	2,741	4,628	3,465	3,27 %
VECM	1,560	1,170	1,10 %	3,618	2,763	4,652	3,489	3,29 %
Marche aléatoire et GJR-GARCH-t	1,560	1,170	1,10 %	3,617	2,762	4,650	3,487	3,29 %
LSTM	1,558	1,171	1,10 %	3,672	2,810	4,867	3,668	3,46 %
GRU	1,558	1,170	1,10 %	3,630	2,771	4,770	3,590	3,39 %

Modèle	RMSE h=1	MAE h=1	MAPE h=1	RMSE h=5	MAE h=5	RMSE h=10	MAE h=10	MAPE h=10
Hybride ARIMA et LSTM	1,569	1,175	1,11 %	3,670	2,807	4,866	3,666	3,46 %

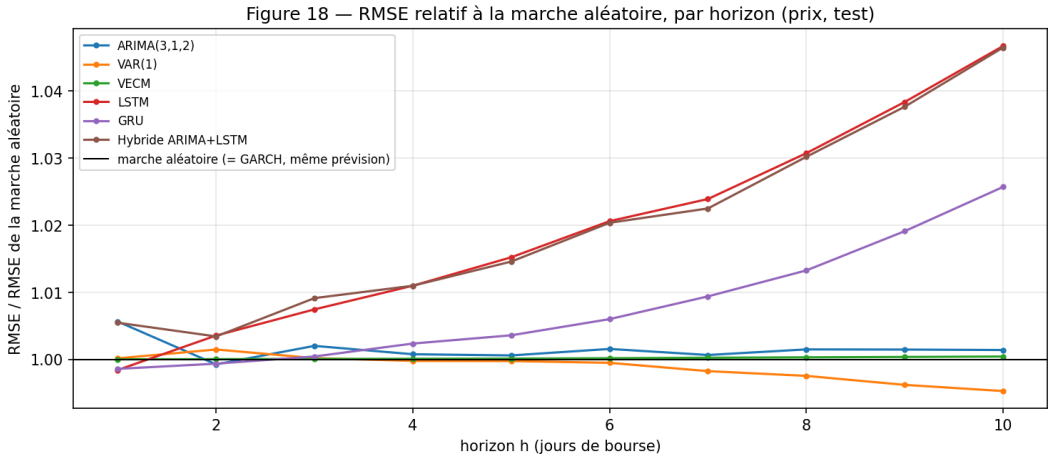


Figure 8. RMSE de chaque modèle rapporté à celui de la marche aléatoire, selon l'horizon (figure 18 du notebook).

Aucun modèle ne fait nettement mieux que la marche aléatoire (figure 8). Le VAR(1) est le seul à faire légèrement mieux à moyen terme, avec un RMSE inférieur de 0,5 % à 10 jours. Les réseaux font jeu égal à un jour mais se dégradent avec l'horizon (RMSE supérieur de 2,6 % à 4,7 % à 10 jours) : leur légère prévision de baisse s'accumule alors que le cours de XOM a progressé de 17 % en 2025, de 100,69 $ à 117,97 $. Le modèle associant la marche aléatoire au GARCH présente exactement les mêmes erreurs que la marche aléatoire, puisque sa moyenne conditionnelle est nulle.

6.3 Test de Diebold-Mariano

Le test de Diebold et Mariano (1995) compare la précision de chaque modèle à celle de la marche aléatoire. Pour un horizon h, on note $d_t = e_{1,t}^2 - e_{2,t}^2$ la différence des pertes quadratiques du modèle et de la marche aléatoire. La statistique est

$$DM = \frac{\bar{d}}{\sqrt{\hat{V}(\bar{d})}}, \qquad \hat{V}(\bar{d}) = \frac{1}{n}\left(\hat{\gamma}_0 + 2\sum_{k=1}^{h-1}\hat{\gamma}_k\right),$$

où les $\hat{\gamma}_k$ sont les autocovariances empiriques de d_t. Elle est corrigée selon Harvey, Leybourne et Newbold (1997) par le facteur $\sqrt{(n+1-2h+h(h-1)/n)/n}$ et comparée à une loi de Student à n − 1 degrés de liberté. Une statistique positive signifie que le modèle est moins précis que la marche aléatoire. Ce test, programmé par nos soins, est reproduit exactement par la fonction dm.test du paquet R *forecast*, l'écart maximal étant de 7×10^{-15} sur 18 tests.

Tableau 12. Test de Diebold-Mariano contre la marche aléatoire (perte quadratique).

Modèle comparé à la marche aléatoire	p (h = 1)	p (h = 5)	DM (h = 10)	p (h = 10)	Décision à h = 10
VAR(1)	0,985	0,976	−0,40	0,69	pas de différence
VECM	0,839	0,608	1,01	0,32	pas de différence

Modèle comparé à la marche aléatoire	p (h = 1)	p (h = 5)	DM (h = 10)	p (h = 10)	Décision à h = 10
ARIMA(3,1,2)	0,411	0,384	4,11	< 0,001	moins précis
LSTM	0,756	0,178	2,56	0,011	moins précis
GRU	0,728	0,686	4,45	< 0,001	moins précis
Hybride ARIMA et LSTM	0,531	0,180	2,69	0,008	moins précis

L'hypothèse nulle d'égale précision n'est rejetée en faveur d'aucun modèle, à aucun horizon compris entre 1 et 10 jours (tableau 12). Elle est rejetée en défaveur de l'ARIMA(3,1,2) et des réseaux à l'horizon de 10 jours. La marche aléatoire demeure ainsi la meilleure prévision du prix, conformément à l'efficience faible du marché, et ce sur des données que les modèles n'ont jamais vues.

6.4 Intervalles de prévision et prévision de la variance

La qualité des intervalles de prévision à 95 % est évaluée par leur taux de couverture, comparé au taux nominal par un test binomial (tableau 13).

Tableau 13. Couverture et largeur des intervalles de prévision sur le test.

Intervalles à 95 %, h = 1	Couverture	Test binomial (H_0 : 95 %)	Largeur moyenne	Couverture à h = 10
Variance constante (marche aléatoire, ARIMA, VAR, VECM)	98,0 à 98,4 %	p = 0,009 à 0,028 : rejet	7,42 à 7,46 $	96,3 %
GJR-GARCH-t (intervalles simulés)	94,8 %	p = 0,885 : non-rejet	6,27 $	94,7 %

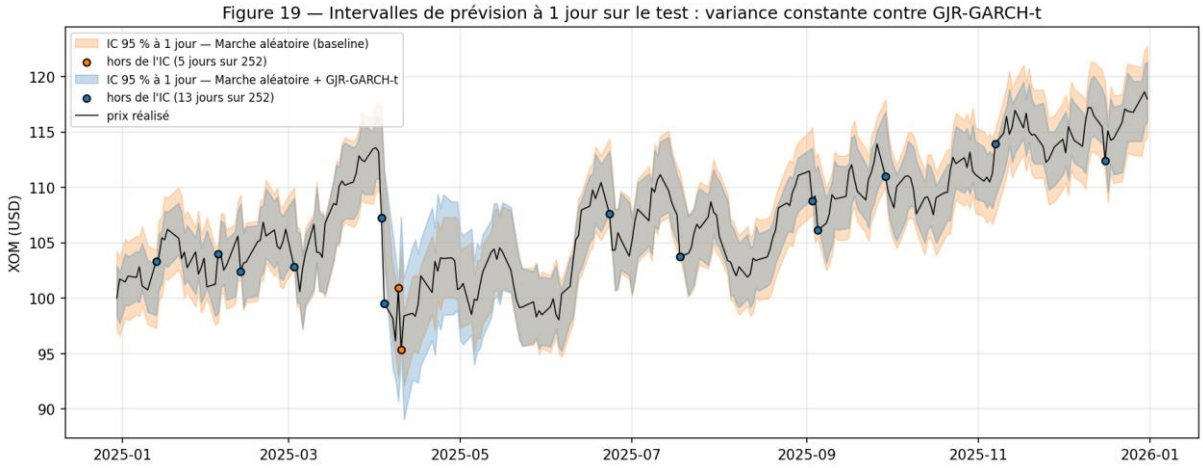


Figure 9. Intervalles de prévision à un jour sur l'échantillon de test : variance constante et GJR-GARCH-t (figure 19 du notebook).

Les intervalles fondés sur une variance constante sont trop larges, car cette variance agrège tout le passé, y compris la crise de 2020, alors que l'année 2025 est plus calme (figure 9). Le GJR-GARCH-t atteint une couverture correcte avec des intervalles plus étroits de 16 %, parce qu'il s'adapte au régime de volatilité courant. C'est le résultat le plus utile de l'évaluation : si aucun modèle ne prévoit mieux le niveau du prix, le GARCH en prévoit mieux l'incertitude.

La variance prévue à un jour est évaluée séparément à l'aide de la perte QLIKE (Patton, 2011), $L_t = \ln\hat{\sigma}_t^2 + r_{t+1}^2/\hat{\sigma}_t^2$, qui reste fiable lorsque le rendement au carré sert d'approximation bruitée de la variance. Le GJR-GARCH-t obtient la perte la plus faible (1,732), devant le lissage exponentiel EWMA (1,738), la volatilité réalisée sur 21 jours

(1,764) et la variance constante (1,844). L'écart avec la variance constante n'est toutefois significatif qu'au seuil de 10 % (Diebold-Mariano, p = 0,075) : une seule année de test, qui ne comporte qu'une véritable période agitée (avril 2025), offre une puissance limitée. Les paramètres du GJR restent stables sur les 13 ré-estimations (γ entre 0,039 et 0,046, β entre 0,933 et 0,936).

6.5 Comparaison détaillée et choix du modèle

Le tableau 14 confronte les modèles selon la précision, la calibration des intervalles, l'interprétabilité et le coût de calcul.

Tableau 14. Comparaison détaillée des modèles.

Modèle	RMSE h=10 ($)	Écart à la référence	Diebold-Mariano h=10	Couverture IC 95 % h=1	Interprétabilité	Coût de calcul
Marche aléatoire	4,650	référence		98,0 %	totale	nul
ARIMA(3,1,2)	4,657	+0,1 %	moins précis	98,0 %	faible (racines compensées)	14 s (13 estimations)
VAR(1)	4,628	−0,5 %	non significatif	98,4 %	bonne (IRF, Granger)	moins de 1 s
VECM	4,652	+0,04 %	non significatif	98,0 %	bonne (équilibre, demi-vie)	moins de 1 s
Marche aléatoire et GJR-GARCH-t	4,650	0	identique	94,8 %	bonne (levier, persistance)	5 s (13 estimations)
LSTM	4,867	+4,7 %	moins précis		très faible	grille de 80 entraînements (environ 10 min) et 3 graines
GRU	4,770	+2,6 %	moins précis		très faible	idem
Hybride ARIMA et LSTM	4,866	+4,6 %	moins précis		très faible	ARIMA et 3 graines de LSTM

Le modèle finalement retenu associe un ARIMA(0,1,0) à un GJR-GARCH(1,1) à loi de Student. Pour le niveau du prix, la marche aléatoire n'est battue par aucun modèle ; elle est en outre sans coût et parfaitement interprétable. Pour le risque, qu'il s'agisse des intervalles de prévision, de la valeur à risque ou du dimensionnement des positions, le GJR-GARCH-t est le seul modèle bien calibré, tout en restant interprétable et peu coûteux. Le VAR et le VECM servent à comprendre le lien entre XOM et XLE plutôt qu'à prévoir. L'évaluation hors échantillon confirme ainsi le choix établi sur l'apprentissage à la section 4.

7. Extensions

7.1 Corrélation dynamique

La corrélation entre les rendements de XOM et de XLE, calculée sur des fenêtres glissantes de 60 jours, varie sensiblement au cours du temps : 0,82 en moyenne sur 2016-2019, 0,94 en 2020, 0,93 sur 2021-2024 et 0,88 en 2025. La hausse de niveau (+0,11) excède nettement l'incertitude d'une corrélation estimée sur 60 jours, de l'ordre de ±0,05. Après chacun des six événements documentés, la corrélation mesurée 60 jours plus tard est plus élevée, par

exemple de 0,88 à 0,95 après l'annonce des droits de douane d'avril 2025. En période de crise, le choc commun domine et la diversification au sein du secteur disparaît.

Le modèle DCC-GARCH d'Engle (2002) formalise cette dynamique :

$$Q_t = (1 - a - b)\,\bar{Q} + a\,\boldsymbol{z}_{t-1}\boldsymbol{z}'_{t-1} + b\,Q_{t-1},$$

où $\boldsymbol{z}_t$ est le vecteur des rendements standardisés par leurs GARCH univariés et où la matrice de corrélation conditionnelle s'obtient en normalisant Q_t. Estimé sur l'apprentissage par notre propre code et vérifié avec le paquet R *rmgarch*, il donne a = 0,026 (erreur-type 0,006) et b = 0,970 (0,008). La corrélation réagit donc au choc commun de la veille et persiste longtemps, la demi-vie d'un choc étant d'environ 145 jours. Le test d'Engle et Sheppard (2001), dont l'hypothèse nulle est une corrélation constante, la rejette nettement : $\chi^2(6) = 34{,}3$, $p < 0{,}0001$, et 32,1 hors 2020.

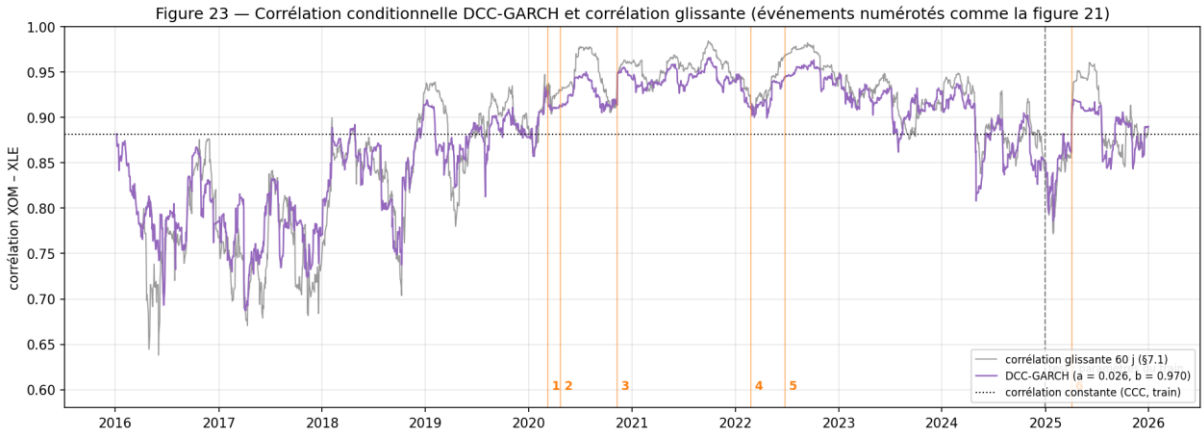


Figure 10. Corrélation conditionnelle DCC-GARCH et corrélation glissante sur 60 jours ; les numéros d'événements renvoient à la figure 21 du notebook (figure 23 du notebook).

La corrélation DCC suit la corrélation glissante, avec laquelle elle est corrélée à 0,946, tout en étant plus lisse et plus réactive (figure 10). Filtrée sur 2025 avec les paramètres estimés sur l'apprentissage, elle culmine à 0,92 le 11 avril 2025. Ce résultat a une application directe : le ratio de couverture de XOM par XLE, $\beta_t = \rho_t\,\sigma_{XOM,t}/\sigma_{XLE,t}$, varie dans le temps, et le calculer avec une corrélation constante le fausserait dans un sens comme dans l'autre.

7.2 Le Brent comme variable exogène

Nous avons estimé un VAR(1) des rendements de XOM et de XLE augmenté du rendement du Brent, soit du jour même, soit de la veille. L'estimation est faite par moindres carrés ordinaires équation par équation, avec des erreurs-types HC3, et les résultats sont identiques à ceux de *statsmodels* (tableau 15).

Tableau 15. Effet du rendement du Brent dans l'équation de XOM (VARX).

Version	Coefficient du Brent (équation de XOM)	p-value HC3	R^2 de l'équation de XOM	Hors 2020
Brent du jour même	0,371	< 0,001	de 0,4 % à 27,9 %	0,374 ; p < 0,001
Brent de la veille	−0,005	0,86	inchangé	−0,027 ; p = 0,24

Le Brent explique les rendements de XOM le jour même, une hausse de 1 % du Brent s'accompagnant d'une hausse de 0,37 % de XOM, mais le Brent de la veille ne prévoit rien.

Sur l'échantillon de test, le VARX ne fait mieux ni que le VAR(1) ni que la marche aléatoire (Diebold-Mariano, p = 0,69 à 10 jours) ; il a été évalué selon le même protocole que les modèles du tableau 11. Le lien entre XOM et le Brent reste d'ailleurs lâche, avec une corrélation de 0,53. Le 21 avril 2020, le Brent perd 24,4 % alors que XOM ne recule que de 0,5 %. XOM demeure avant tout une action, sensible au marché boursier et à la politique propre de l'entreprise, et pas seulement au prix du pétrole.

7.3 Extension non réalisée

Une analyse du sentiment des communiqués de l'entreprise à l'aide du modèle FinBERT a été écartée pour une raison méthodologique. Le corpus disponible sur l'ensemble de la période ne compte qu'une quarantaine d'annonces de résultats, ce qui est insuffisant pour tester de façon fiable un effet du sentiment sur les rendements. Nous avons préféré approfondir la corrélation dynamique et le rôle de la variable exogène.

8. Apport de l'intelligence artificielle générative

8.1 Protocole

Conformément au cahier des charges, nous avons d'abord rédigé notre propre interprétation des résultats, datée du 8 novembre 2026 (annexe B), avant de solliciter un modèle de langage (ChatGPT, agent GPT-6), chaque fois dans une nouvelle conversation. Trois tâches lui ont été confiées : formuler des hypothèses de modèles à partir des seules statistiques descriptives et des tests de stationnarité ; vulgariser nos résultats à l'intention d'un directeur financier non statisticien ; enfin, formuler des recommandations d'investissement simulées à partir de nos prévisions, en énonçant lui-même leurs limites. Un premier envoi de la troisième tâche a eu lieu par erreur sans les données ; nous l'avons conservé, car il est instructif.

Les prompts et les réponses intégrales figurent en annexe C. Chaque réponse a été confrontée à une grille de neuf types d'erreurs à rechercher, parmi lesquelles les p-values inventées, la causalité attribuée au test de Granger, la direction des prix attribuée au GARCH, les causes non fondées et l'excès de confiance.

8.2 Résultats de la comparaison

Le tableau 16 classe les observations issues de cette comparaison, détaillée en annexe D.

Tableau 16. Synthèse de la comparaison entre notre interprétation et celle du modèle de langage.

Type d'observation	Nombre	Exemples
Convergences et comportements corrects	5	Association marche aléatoire et GARCH-t proposée d'emblée ; aucune p-value inventée ; tests correctement lus ; absence de données signalée
Divergence	1	Rendement retardé de XLE proposé comme prédicteur, alors que notre test de Granger robuste le rejette
Oublis	2	Aucun test de cointégration alors que les deux log-prix sont intégrés ; FEVD passée sous silence
Simplifications ou ajouts non fondés	3	Persistance du GARCH prise à la lettre ; cause des pics de 2022 avancée sans source ; corrélation des chocs présentée comme celle des rendements
Erreurs de raisonnement	2	Recommandation d'achat « si la prévision est favorable » avec une

Type d'observation	Nombre	Exemples
		marche aléatoire, dont la prévision est constante ; recommandation de conservation justifiée par l'absence de signal de vente
GARCH présenté comme prévoyant la direction	2	« Direction des prévisions » ; « ne prédit pas avec certitude la direction du cours »
Vocabulaire causal ou statistique impropre	2	« Influence » pour le test de Granger ; « intervalle de confiance » pour un intervalle de prévision

Le modèle de langage retrouve rapidement les grandes lignes d'une stratégie de modélisation adaptée, à savoir un ARIMA associé à un GARCH à loi de Student et les diagnostics correspondants, et il reformule clairement des résultats vérifiés à l'intention d'un public non spécialiste. Il a permis de gagner du temps sur la rédaction et la structuration, et sa suggestion d'un modèle EGARCH ou GJR rejoint notre propre choix.

Il ne contrôle pas, en revanche, la cohérence entre un modèle et la décision qui en découle. Il envisage des scénarios impossibles avec une marche aléatoire et recommande de conserver l'action sans justification. Il omet les résultats qui nuancent l'analyse, comme la fragilité de la cointégration ou la dépendance de la FEVD à l'ordre des variables, et il ajoute des explications causales qui ne lui ont pas été fournies. Un décideur qui ne lirait que ses réponses retiendrait une image trop simple et trop assurée des résultats.

8.3 Déclaration relative à l'usage d'outils d'IA

Le code du projet a été développé avec l'aide d'un assistant de programmation (Claude Code). Chaque résultat a été exécuté et vérifié, notamment par la comparaison entre R et Python et par des contrôles croisés avec *statsmodels*, la fonction dm.test du paquet *forecast* et le paquet *rmgarch* ; chaque étape doit pouvoir être expliquée en soutenance. Le modèle de langage de la présente section a été utilisé séparément, comme un outil d'analyse dont nous évaluons la fiabilité.

9. Discussion et conclusion

9.1 Limites des modèles

Plusieurs hypothèses des modèles ne sont pas vérifiées. Les résidus ne sont jamais normaux, le test de Jarque-Bera rejetant la normalité pour tous les modèles, et un effet ARCH résiduel subsiste après le GJR (ARCH-LM, $p = 0{,}016$). Les erreurs-types robustes et la loi de Student atténuent ces écarts sans les supprimer.

L'année 2020 pèse sur plusieurs résultats : le choix de l'ordre du VAR par les critères d'information, l'autocorrélation apparente des rendements, la persistance du GARCH (0,999 contre 0,893 avant 2020) et la significativité du SARIMA. Nous l'avons vérifié systématiquement par des analyses excluant 2020 ou portant sur les rendements standardisés, mais un modèle à changement de régime serait mieux adapté à cette rupture.

L'échantillon de test se limite à une année, calme et haussière (+17 %), qui ne constitue qu'une réalisation de l'histoire. Le test portant sur la variance ($p = 0{,}075$) manque de puissance, et le classement des modèles pourrait différer dans un régime de crise. Par ailleurs, les réseaux n'ont pas été ré-entraînés au cours du test, ce qui ne les désavantage guère

puisqu'ils n'apprennent rien sur l'apprentissage, et leur grille d'hyperparamètres est restreinte. Les coûts de transaction ont été ignorés, ce qui ne pourrait que renforcer la conclusion. Enfin, la cointégration est fragile et sensible aux premières observations : la demi-vie de 62,6 jours n'est qu'une estimation ponctuelle à interpréter avec prudence.

9.2 L'IA générative appliquée aux séries temporelles

L'IA générative se révèle utile comme outil d'assistance. Elle accélère l'écriture du code, la recherche de méthodes et la reformulation, et elle propose des pistes raisonnables. En séries temporelles financières, ses faiblesses sont cependant particulièrement dangereuses. Elle raisonne par associations plausibles, du type « le pétrole monte, donc XOM montera demain », confond explication et prévision et attribue facilement des causes à de simples corrélations. Elle ne vérifie ni les hypothèses d'un test ni la cohérence d'une recommandation.

Son usage exige donc un contrôle humain systématique : une interprétation personnelle rédigée au préalable, la vérification de chaque chiffre au regard des sorties du code et une grille d'erreurs explicite. Dans ces conditions, elle fait gagner du temps sans dégrader la rigueur de l'analyse. Utilisée sans ce contrôle, elle conduirait à des recommandations d'investissement trop assurées et insuffisamment fondées.

9.3 Conclusion

Ce travail apporte une réponse claire à la question posée. Le prix de XOM n'est pas prévisible à un horizon de 1 à 10 jours mieux que par une marche aléatoire. Ni les modèles linéaires (ARIMA, VAR, VECM, VARX) ni les réseaux de neurones (LSTM, GRU, modèle hybride) ne la battent significativement hors échantillon, et plusieurs font significativement moins bien. Ce résultat négatif est cohérent à toutes les étapes de l'analyse, de l'étude exploratoire au test de Diebold-Mariano, et il est conforme à l'efficience faible du marché.

Le risque est en revanche prévisible. Le GJR-GARCH à loi de Student capte le regroupement des fortes variations et l'effet de levier, et il fournit les seuls intervalles de prévision correctement calibrés sur l'année 2025. Le lien entre XOM et son secteur est fort, essentiellement contemporain, et varie dans le temps, comme le montre le DCC-GARCH.

Ces conclusions illustrent un principe rappelé par le cahier des charges : un modèle simple et bien diagnostiqué vaut mieux qu'un modèle complexe insuffisamment validé. Trois prolongements paraissent naturels : des modèles à changement de régime pour la volatilité, des réseaux de neurones appliqués à la variance plutôt qu'à la moyenne, et une analyse du sentiment fondée sur un corpus de presse quotidien de grande taille.

Les sources des faits externes cités (événements de marché, composition de l'ETF XLE) sont recensées dans le fichier docs/sources.md ; chaque fait y est recoupé avec nos données lorsque c'est possible.

Références bibliographiques

Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307-327.

Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *The Review of Economics and Statistics*, 69(3), 542-547.

Bollerslev, T. et Wooldridge, J. M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143-172.

Box, G. E. P. et Jenkins, G. M. (1976). *Time Series Analysis: Forecasting and Control* (édition révisée). San Francisco : Holden-Day.

Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H. et Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1724-1734.

Cleveland, R. B., Cleveland, W. S., McRae, J. E. et Terpenning, I. (1990). STL: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, 6(1), 3-73.

Dickey, D. A. et Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427-431.

Diebold, F. X. et Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253-263.

Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987-1007.

Engle, R. F. (2002). Dynamic conditional correlation: A simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339-350.

Engle, R. F. et Granger, C. W. J. (1987). Co-integration and error correction: Representation, estimation, and testing. *Econometrica*, 55(2), 251-276.

Engle, R. F. et Sheppard, K. (2001). Theoretical and empirical properties of dynamic conditional correlation multivariate GARCH. *NBER Working Paper* n° 8554.

Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383-417.

Glosten, L. R., Jagannathan, R. et Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *The Journal of Finance*, 48(5), 1779-1801.

Granger, C. W. J. (1969). Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3), 424-438.

Harvey, D., Leybourne, S. et Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281-291.

Hochreiter, S. et Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780.

Hosking, J. R. M. (1980). The multivariate portmanteau statistic. *Journal of the American Statistical Association*, 75(371), 602-608.

Jarque, C. M. et Bera, A. K. (1980). Efficient tests for normality, homoscedasticity and serial independence of regression residuals. *Economics Letters*, 6(3), 255-259.

Johansen, S. (1991). Estimation and hypothesis testing of cointegration vectors in Gaussian vector autoregressive models. *Econometrica*, 59(6), 1551-1580.

Kruskal, W. H. et Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583-621.

Kwiatkowski, D., Phillips, P. C. B., Schmidt, P. et Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54(1-3), 159-178.

Lamoureux, C. G. et Lastrapes, W. D. (1990). Persistence in variance, structural change, and the GARCH model. *Journal of Business & Economic Statistics*, 8(2), 225-234.

Ljung, G. M. et Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297-303.

MacKinnon, J. G. et White, H. (1985). Some heteroskedasticity-consistent covariance matrix estimators with improved finite sample properties. *Journal of Econometrics*, 29(3), 305-325.

Newey, W. K. et West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703-708.

Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246-256.

Sims, C. A. (1980). Macroeconomics and reality. *Econometrica*, 48(1), 1-48.

Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, 50, 159-175.

Zivot, E. et Andrews, D. W. K. (1992). Further evidence on the great crash, the oil-price shock, and the unit-root hypothesis. *Journal of Business & Economic Statistics*, 10(3), 251-270.

Annexes

Annexe A. Reproduction des résultats

Tableau A.1. Commandes de reproduction.

Étape	Commande
Installation complète (Python 3.11 et R 4.3 ou plus récent)	`python install.py` ; l'environnement Python est placé dans un dossier court si le chemin du projet dépasse la limite de 260 caractères de Windows, puis les paquets R sont installés
Exécution des deux notebooks	`python run_all.py` (notebook Python en 13 min environ, puis document R en 1 min 30 s environ)
Environnement Python, installation manuelle	`pip install -r requirements.txt` (versions exactes dans requirements-lock.txt)
Environnement R, installation manuelle	`Rscript install_packages.R` (instantané CRAN daté)
Étude complète en Python, exécution manuelle	`jupyter nbconvert --to notebook --execute notebooks/main_python.ipynb`
Socle classique en R	`Rscript -e "rmarkdown::render('notebooks/classical_R.Rmd')"`, après le notebook Python dont il relit les exports
Rapport Word	`python rapport/build_rapport.py`

Les paramètres de l'étude (symboles boursiers, dates, découpage, horizon, graine) sont centralisés dans le fichier config.yaml, et les données sont figées dans data/raw/. Les tableaux détaillés au format CSV se trouvent dans outputs/tables/, numérotés comme dans le notebook, et les figures dans outputs/figures/.

Annexe B. Interprétation personnelle, rédigée avant l'usage du LLM

Auteurs : Aziz Bellaaj, Mohamed Yassine Khiari
Date de rédaction (avant tout prompt LLM) : 2026-11-08

> Cette page est rédigée par l'étudiant, **avant** d'interroger le LLM. Elle sert de référence pour la comparaison humain / LLM (cahier §5). Environ une page. Pour chaque point, suivre la méthode : hypothèse nulle → statistique et p-value → décision → sens concret → conséquence.

1. Stationnarité et ordre de différenciation

H_0 de l'ADF : racine unitaire (série non stationnaire). H_0 du KPSS : série stationnaire. Les deux hypothèses sont opposées, donc on conclut quand les deux tests concordent.

Log-prix : l'ADF ne rejette pas H_0 ($p = 0{,}76$) et le KPSS rejette H_0 ($p < 0{,}01$). Les deux tests concordent : le log-prix n'est pas stationnaire.

Rendements : l'ADF rejette H_0 ($p < 0{,}001$) et le KPSS ne rejette pas H_0 ($p > 0{,}10$). Les deux tests concordent : les rendements sont stationnaires.

Le log-prix devient stationnaire après 1 différenciation, donc $d = 1$. On modélise donc les rendements et non les prix.

2. Dynamique de la moyenne (ARIMA, SARIMA)

Je retiens l'ARIMA(0,1,0) car le BIC, qui pénalise davantage la complexité, le choisit, et car l'ARIMA(3,1,2) proposé par l'AIC n'est pas meilleur : ses résidus restent autocorrélés ($p = 0{,}013$).

Le coefficient saisonnier a $p = 0{,}12 > 0{,}05$: on ne rejette pas H_0, donc on écarte le SARIMA.

ARCH-LM sur les résidus de la marche aléatoire : 441, $p \approx 0 < 0{,}05$: on rejette H_0. La variance n'est pas constante : les grosses variations arrivent en grappes, par exemple en 2020. Il faut donc ajouter un modèle GARCH.

3. Lien entre XOM et XLE (VAR, Granger, IRF/FEVD, cointégration)

Granger de XLE vers XOM : avec le test robuste, $p = 0{,}20 > 0{,}05$: on ne rejette pas H_0. Le passé de XLE n'améliore pas la prévision de XOM.

IRF : XOM réagit le jour même à un choc sur XLE (+1,63 %). Il n'y a pas d'effet retardé, ce qui est cohérent avec Granger.

FEVD : la part de XLE vaut 84 % ou 0,3 % selon l'ordre. On ne peut pas dire que XLE entraîne XOM, car le résultat dépend de l'ordre des variables. On ne peut donc pas dire qui entraîne qui.

La cointégration est fragile : elle n'est retenue qu'à 10 % et disparaît dans les sous-périodes.

4. Volatilité (GARCH)

H_0 : $\gamma = 0$. Avec $p = 0{,}004$, on rejette H_0. Une baisse augmente la volatilité de $\alpha + \gamma = 0{,}085$, contre $\alpha = 0{,}043$ pour une hausse. Un investisseur doit donc s'attendre à plus de risque après une baisse. Le GARCH prévoit l'amplitude des variations, pas leur sens.

La persistance de 0,999 est gonflée par la rupture de 2020. Le GARCH confond un changement de niveau de la volatilité avec une forte persistance. Sur 2016–2019, elle n'est que de 0,893.

5. Deep learning (LSTM, GRU, hybride)

Le meilleur modèle est la marche aléatoire (RMSE 1,8450). Le LSTM (1,8472) ne bat pas la marche aléatoire. Ce n'est pas un échec, car les rendements sont un bruit blanc en moyenne : il n'y a rien à prévoir.

6. Ce que ces résultats ne permettent pas de conclure

On ne peut pas dire que XLE « cause » XOM. Le GARCH prévoit le risque, pas le sens du prix. Les résultats peuvent changer si le marché change de régime, comme en 2020.

Annexe C. Prompts et réponses intégrales du LLM

Chaque prompt a été envoyé dans une nouvelle conversation. Les réponses sont reproduites sans retouche.

C.1 Tâche 1 : hypothèses de modèles

Prompt envoyé

Je travaille sur une série temporelle financière journalière : le rendement logarithmique en pourcentage, r_t = 100 × Δln(P_t), de l'action Exxon Mobil (XOM, cours ajusté Yahoo Finance). J'ai aussi le rendement de l'ETF sectoriel de l'énergie XLE, dont XOM est le premier composant. L'échantillon d'apprentissage va du 2016-01-04 au 2024-12-27 (2 261 rendements).

Statistiques descriptives des rendements (en %) :

	XOM	XLE
Moyenne	0,0319	0,0315
Variance	3,185	3,692
Écart-type	1,785	1,922
Skewness	−0,163	−0,890
Excès de kurtosis	6,62	16,44
Min / max	−13,04 / +11,94	−22,49 / +14,87
Jarque-Bera	4 142 (p < 0,001)	25 747 (p < 0,001)

Test de la moyenne de XOM (t de Student HAC, Newey-West, 7 retards) : t = 0,86, p = 0,39.

Tests de stationnarité :

Série	Spécification	ADF (retards), p-value	KPSS (retards), p-value
Log-prix XOM	constante	−0,971 (18), p = 0,76	3,563 (29), p < 0,01
Log-prix XOM	constante + tendance	−1,600 (18), p = 0,79	1,397 (29), p < 0,01
Rendement XOM	constante	−10,557 (17), p < 0,001	0,144 (8), p > 0,10
Log-prix XLE	constante	−1,503 (7), p = 0,53	3,586 (29), p < 0,01
Rendement XLE	constante	−16,064 (6), p < 0,001	0,084 (9), p > 0,10

Autocorrélation et hétéroscédasticité des rendements de XOM :
- Ljung-Box Q(10) sur les rendements : 34,9 (p = 0,0001).
- Ljung-Box Q(10) sur les rendements divisés par la volatilité des 21 jours précédents : p = 0,98.
- Ljung-Box Q(10) sur les rendements, année 2020 exclue : p = 0,44.
- ACF des rendements au carré : 40 retards sur 40 hors de la bande à 95 %.
- ARCH-LM(5) : 441,2 (p < 0,001).

Questions :
1. Quels modèles me recommandes-tu de tester, et pourquoi ? Justifie chaque proposition par les statistiques ci-dessus.
2. Quel ordre de différenciation d retiens-tu ? Quels ordres p et q faut-il essayer en premier ?
3. Quelle loi d'innovation choisir, et pourquoi ?
4. Quels diagnostics faudra-t-il faire sur les résidus ?
5. Qu'est-ce qui pourrait te faire changer d'avis ?

Réponse du LLM

- **Modèle :** ChatGPT, agent GPT-6 (nom donné par l'étudiant)
- **Date :** 2026-11-08
- **Prompt :** `llm/prompts/01_hypotheses.md`, envoyé dans une nouvelle conversation
- **Réponse :** intégrale, copiée sans retouche ci-dessous

Analyse et stratégie de modélisation de la série temporelle XOM
À partir des statistiques fournies, je recommande une approche ARIMA pour la dynamique de la moyenne, combinée à un modèle GARCH pour la volatilité conditionnelle, avec une loi d'innovation à queues épaisses, notamment Student-t.

Le point essentiel est de distinguer deux phénomènes dans tes données :
1. La dynamique de la moyenne : les rendements présentent une autocorrélation statistiquement significative, mais celle-ci semble principalement liée à certaines périodes exceptionnelles, notamment 2020.
2. La dynamique de la variance : les rendements présentent une forte hétéroscédasticité conditionnelle et des effets ARCH très importants.
Il ne faut donc pas chercher à expliquer toute la structure des rendements avec un simple ARIMA.
1. Quels modèles recommander ?
A. ARIMA : modélisation de la moyenne
Les résultats ADF et KPSS indiquent que :
- Le logarithme du prix XOM est non stationnaire.
- Le rendement XOM est stationnaire.
- Le rendement XLE est également stationnaire.
La transformation logarithmique suivie d'une première différenciation permet donc d'obtenir une série stationnaire.

L'ARIMA est pertinent pour examiner la dépendance linéaire entre les rendements.

Je recommande de tester :
Modèle · Intérêt
ARIMA(0,0,0) · Modèle de référence : rendement assimilé à un bruit blanc autour d'une constante.
ARIMA(1,0,0) · Vérifier une dépendance au premier retard.
ARIMA(0,0,1) · Vérifier une dépendance de type moyenne mobile.
ARIMA(1,0,1) · Capturer une combinaison AR et MA.
ARIMA(2,0,1) · Tester une dynamique légèrement plus complexe.
ARIMA(1,0,2) · Vérifier si plusieurs retards MA améliorent l'ajustement.

Pourquoi ne pas privilégier un ARIMA complexe ?

Le test de Ljung-Box donne :
- Sur les rendements : p = 0,0001.
- En excluant 2020 : p = 0,44.
- Après standardisation par la volatilité passée : p = 0,98.
Cela suggère que l'autocorrélation détectée sur l'ensemble de l'échantillon pourrait être liée à des épisodes particuliers plutôt qu'à une dépendance persistante de la moyenne.

Par conséquent, ARIMA(0,0,0) doit rester un candidat sérieux.
B. GARCH : modélisation de la volatilité
C’est ici que tes statistiques sont particulièrement révélatrices.

Trois résultats sont importants :
- ACF des rendements au carré : 40 retards sur 40 significatifs.
- ARCH-LM(5) : 441,2 avec p inférieur à 0,001.
- Ljung-Box sur les rendements standardisés : p = 0,98.
Ces résultats indiquent une forte dépendance dans la variance conditionnelle.

Le modèle GARCH(1,1) constitue donc le premier modèle à tester.
\[
r_t = \mu_t+\varepsilon_t
\]

\[
\varepsilon_t=\sigma_t z_t
\]

\[
\sigma_t^2=\omega+\alpha_1\varepsilon_{t-1}^2
+\beta_1\sigma_{t-1}^2
\]

Avec :
- \(\omega\) : constante de variance.
- \(\alpha_1\) : réaction de la volatilité aux nouveaux chocs.
- \(\beta_1\) : persistance de la volatilité.
- \(z_t\) : innovation standardisée.
Je recommande ensuite de comparer :
Modèle · Justification
ARCH(1) · Modèle de référence pour les effets ARCH.
GARCH(1,1) · Capture les chocs et la persistance de la volatilité.
GARCH(1,2) · Vérifie si plusieurs retards de variance améliorent le modèle.
GARCH(2,1) · Vérifie une dynamique plus riche des chocs.
GARCH(1,1)-t · Prend en compte les queues épaisses.

C. Modèles asymétriques : EGARCH et GJR-GARCH
Les statistiques montrent une asymétrie négative :
- XOM : skewness = −0,163.
- XLE : skewness = −0,890.
De plus, les rendements présentent des queues très épaisses.

Cela justifie de tester des modèles capables de prendre en compte une réaction différente de la volatilité aux chocs positifs et négatifs.

EGARCH(1,1)

Modélise le logarithme de la variance et permet de prendre en compte l’asymétrie des chocs.

GJR-GARCH(1,1)

Permet de vérifier si les chocs négatifs ont un effet plus important sur la volatilité que les chocs positifs.

Attention : une skewness négative ne prouve pas à elle seule l'existence d'un effet de levier. Il faudra vérifier la significativité du paramètre d'asymétrie.

D. Intégrer XLE : modèle ARMAX-GARCH

Tu disposes d'une information supplémentaire intéressante : le rendement de XLE.

Puisque XOM est le premier composant de cet ETF, les deux séries sont économiquement liées.

Je recommande donc de tester une extension avec XLE comme variable explicative :

$$
r_t^{XOM}=\mu+\phi r_{t-1}^{XOM}
+\gamma r_{t-1}^{XLE}+\varepsilon_t
$$

Puis :

$$
\sigma_t^2=\omega+\alpha\varepsilon_{t-1}^2
+\beta\sigma_{t-1}^2
$$

Cela correspond à une structure ARMAX-GARCH.

Pourquoi utiliser le rendement retardé de XLE ?

- Il permet d'étudier si les mouvements du secteur énergétique contribuent à expliquer les rendements futurs de XOM.
- Il peut améliorer la prévision de la moyenne conditionnelle.
- Il permet d'étudier la relation entre une action et son secteur.

Je privilégierais d'abord XLE retardé plutôt que contemporain : XOM étant lui-même une composante de XLE, une relation contemporaine peut être en partie mécanique.

Il faudra également vérifier la corrélation croisée et la significativité du coefficient γ.

2. Quel ordre de différenciation d retenir ? Quels p et q essayer ?

Il faut distinguer deux séries.

Si tu modèles le logarithme du prix :

$$
d=1
$$

Car les tests ADF et KPSS indiquent que le logarithme du prix est non stationnaire.

Le modèle de départ est donc un ARIMA(p,1,q).

Si tu modèles directement les rendements :

$$
\boxed{d=0}
$$

C’est le choix que je recommande puisque tes rendements sont déjà stationnaires.

Il ne faut pas différencier une deuxième fois les rendements : cela risquerait de supprimer une partie de leur dynamique et de produire une série inutilement transformée.

Ordres p et q à tester

Je commencerais par cette grille :

Priorité · p · d · q · Modèle
1 · 0 · 0 · 0 · ARIMA(0,0,0)
2 · 1 · 0 · 0 · ARIMA(1,0,0)
3 · 0 · 0 · 1 · ARIMA(0,0,1)
4 · 1 · 0 · 1 · ARIMA(1,0,1)
5 · 2 · 0 · 1 · ARIMA(2,0,1)
6 · 1 · 0 · 2 · ARIMA(1,0,2)

Je recommande de privilégier les modèles parcimonieux.

Pour sélectionner le meilleur modèle, utiliser :
- AIC : Akaike Information Criterion.
- BIC : Bayesian Information Criterion.
- Significativité des coefficients.
- Qualité des diagnostics des résidus.
- Performance de prévision hors échantillon.

Attention : le modèle ayant le plus petit AIC n’est pas automatiquement le meilleur si ses résidus conservent une autocorrélation significative.

3. Quelle loi d’innovation choisir ?

Premier choix recommandé : Student-t

Tes statistiques descriptives montrent clairement que la loi normale est peu adaptée.

Pour XOM :
- Skewness : −0,163.
- Excès de kurtosis : 6,62.
- Jarque-Bera : 4 142.
- p-value inférieure à 0,001.

Pour XLE :
- Skewness : −0,890.
- Excès de kurtosis : 16,44.
- Jarque-Bera : 25 747.
- p-value inférieure à 0,001.

Ces résultats indiquent des distributions non gaussiennes, avec des queues épaisses.

Comparaison des distributions

Distribution · Intérêt
Normale · Référence de comparaison, mais probablement insuffisante.
Student-t · Capture les queues épaisses.
Student-t asymétrique · Capture les queues épaisses et l’asymétrie.
GED · Offre une flexibilité supplémentaire dans l’épaisseur des queues.

Pourquoi Student-t ?

La loi Student-t possède des queues plus épaisses que la loi normale.

Elle permet donc de mieux représenter les événements extrêmes observés dans les rendements financiers.

Pour XOM, je testerais :
1. GARCH(1,1)-Normal.
2. GARCH(1,1)-Student-t.
3. GJR-GARCH(1,1)-Student-t.
4. EGARCH(1,1)-Student-t.
5. EGARCH(1,1)-Student-t asymétrique.

La comparaison permettra de déterminer si les queues épaisses suffisent ou si une asymétrie supplémentaire est nécessaire.

Je ne choisirais pas automatiquement une loi asymétrique uniquement à partir de la skewness : il faut vérifier son apport statistique et prédictif.

4. Quels diagnostics effectuer sur les résidus ?

C'est une étape essentielle. Un modèle GARCH bien estimé doit éliminer autant que possible la dépendance temporelle de la moyenne et de la variance.

On définit les résidus standardisés :

$$
z_t=\frac{\varepsilon_t}{\sigma_t}
$$

A. Vérifier l'autocorrélation des résidus

Test : Ljung-Box sur les résidus standardisés.

$$
H_0 : \rho_1=\rho_2=\cdots=\rho_h=0
$$

Résultat attendu :

$$
p\text{-value}>0,05
$$

Cela signifie que l'on ne détecte pas d'autocorrélation résiduelle significative.

B. Vérifier l'hétéroscédasticité restante

Test : Ljung-Box sur les résidus standardisés au carré.

$$
z_t^2
$$

Résultat attendu :

$$
p\text{-value}>0,05
$$

Il faut également réaliser un test ARCH-LM sur les résidus standardisés.

Résultat attendu : absence d'effets ARCH résiduels significatifs.

C. Vérifier la distribution des résidus

Effectuer :

- Histogramme des résidus standardisés.
- QQ-plot.
- Test de Jarque-Bera.
- Comparaison avec la loi Student-t estimée.

Il faut vérifier si la loi choisie représente correctement les queues de distribution.

Attention : une distribution Student-t ne garantit pas que les résidus seront parfaitement normaux. Il faut juger leur adéquation à la distribution spécifiée.

D. Vérifier la stabilité du modèle

Il faut notamment examiner :

- La significativité des paramètres.
- La positivité de la variance conditionnelle.
- La convergence de l'estimation.
- La stabilité des paramètres dans le temps.
- La persistance de la volatilité.

Pour un GARCH(1,1) classique, on examine notamment :

$$
\alpha_1+\beta_1<1
$$

Si cette somme est proche de 1, la volatilité est très persistante.

Si elle est supérieure ou égale à 1, les propriétés de stationnarité habituelles du GARCH(1,1) ne sont plus satisfaites.

E. Évaluer les prévisions hors échantillon

Je recommande de réserver une période de test après le 27 décembre 2024.

Par exemple, si les données sont disponibles, utiliser 2025 pour évaluer les prévisions.

Comparer :

- RMSE et MAE pour les prévisions de rendement.
- QLIKE pour les prévisions de variance, avec une mesure de volatilité de référence appropriée.
- La qualité de prévision des épisodes de forte volatilité.

Une validation glissante (rolling window) est également intéressante.

5. Qu'est-ce qui pourrait me faire changer d'avis ?

Plusieurs éléments pourraient modifier le choix initial des modèles.

A. La présence de ruptures structurelles

C'est probablement le premier point à approfondir.

Tu as déjà un résultat particulièrement intéressant :

- Ljung-Box sur l'ensemble de l'échantillon : p = 0,0001.
- Ljung-Box en excluant 2020 : p = 0,44.

Cela suggère que l'autocorrélation pourrait être concentrée dans une période exceptionnelle.

Je vérifierais donc :
- Les ruptures structurelles dans la moyenne.
- Les ruptures structurelles dans la variance.
- La stabilité des paramètres avant, pendant et après 2020.

Si des ruptures importantes sont détectées, je pourrais envisager un modèle avec changement de régime, comme un Markov-Switching GARCH, ou une estimation sur des fenêtres glissantes.

B. La présence d'un effet de levier

Je testerais si les mauvaises nouvelles ont un effet plus important sur la volatilité que les bonnes nouvelles.

Si cet effet est statistiquement significatif, je privilégierais EGARCH ou GJR-GARCH plutôt que GARCH classique.

C. Le rôle réel de XLE

Si les rendements retardés de XLE apportent une information significative, je conserverais une structure ARMAX-GARCH.

En revanche, si son coefficient n'est pas significatif et qu'il n'améliore pas les prévisions hors échantillon, je préférerais un modèle univarié plus simple.

D. Les résultats des diagnostics

Voici quelques situations qui me feraient changer de modèle :

Résultat observé · Décision possible

Autocorrélation résiduelle · Ajouter des termes AR ou MA.

Effets ARCH résiduels · Modifier la structure GARCH.

Asymétrie résiduelle · Tester EGARCH ou GJR-GARCH.

Queues toujours trop épaisses · Tester Student-t asymétrique ou GED.

Ruptures structurelles · Tester des modèles à changement de régime.

Mauvaises prévisions hors échantillon · Reconsidérer la spécification et la période d'estimation.

6. Ma recommandation finale : ordre de travail

Je ne commencerais pas par tester des dizaines de modèles. Je procéderais progressivement.

Stratégie expérimentale proposée

1. Étape 1 — Modèle de moyenne

   ARIMA(0,0,0), ARIMA(1,0,0), ARIMA(0,0,1), ARIMA(1,0,1).
2. Étape 2 — Modèle de volatilité

   ARCH(1), GARCH(1,1), avec innovations normales puis Student-t.
3. Étape 3 — Asymétrie

   GJR-GARCH(1,1)-t et EGARCH(1,1)-t.
4. Étape 4 — Variable explicative

   Tester ARMAX-GARCH avec les rendements retardés de XLE.
5. Étape 5 — Diagnostics

   Ljung-Box, ARCH-LM, QQ-plot, stabilité des paramètres et analyse des ruptures.
6. Étape 6 — Comparaison finale

AIC, BIC, log-vraisemblance et performances hors échantillon.

Les trois modèles que je retiendrais en priorité
Rang · Modèle · Objectif
1 · ARIMA(0,0,0)-GARCH(1,1)-t · Modèle de référence robuste et parcimonieux.
2 · ARIMA(0,0,0)-EGARCH(1,1)-t · Examiner l'asymétrie de la volatilité.
3 · ARMAX(avec XLE)-GJR-GARCH(1,1)-t · Examiner l'apport sectoriel et l'effet de levier.

Une dernière observation importante : ton test HAC de la moyenne donne p = 0,39. Je ne chercherais donc pas à construire un modèle complexe pour expliquer la moyenne des rendements sans preuve supplémentaire. Une constante éventuellement non significative, voire une moyenne conditionnelle nulle comme modèle de référence, est parfaitement défendable.

Ma conclusion : tes données présentent davantage de caractéristiques intéressantes dans la dynamique de la volatilité que dans celle de la moyenne. Le couple ARIMA-GARCH, avec innovations Student-t, constitue donc le meilleur point de départ. L'EGARCH et le GJR-GARCH permettront ensuite de vérifier si la volatilité réagit différemment aux chocs positifs et négatifs.

Je te conseille de conserver une distinction fondamentale dans ton rapport : la stationnarité des rendements ne signifie pas que leur variance est constante. Tes tests montrent précisément qu'une série peut être stationnaire en moyenne tout en présentant une forte hétéroscédasticité conditionnelle.

C.2 Tâche 2 : vulgarisation pour un décideur

Prompt envoyé

Voici les résultats d'une étude statistique sur l'action Exxon Mobil (XOM) et l'ETF de l'énergie XLE, en données journalières de 2016 à 2024. Rédige une explication d'une page, claire et sans jargon, pour un directeur financier qui n'est pas statisticien. Il veut savoir ce qu'il peut et ne peut pas en tirer.

1. Prévision du rendement moyen
- Le modèle retenu est la marche aléatoire, ARIMA(0,1,0) sur le log-prix : la meilleure prévision du rendement de demain est zéro. Le critère BIC choisit ce modèle.
- Le critère AIC propose un ARIMA(3,1,2). Ses racines AR (module 1,047) et MA (module 1,075) se compensent presque, et ses résidus standardisés restent autocorrélés (Ljung-Box p = 0,013). Il est donc écarté.
- Un SARIMA hebdomadaire (s = 5) a été testé et écarté : son coefficient saisonnier n'est pas significatif avec des erreurs-types robustes (p = 0,12).
- Validation sur 5 périodes successives (walk-forward), avec l'erreur quadratique moyenne des rendements journaliers en % (RMSE) :

Modèle	RMSE
Marche aléatoire	1,8450
LSTM	1,8472
GRU	1,8482
ARIMA(3,1,2)	1,8501
Hybride ARIMA + LSTM	1,8527

Aucun réseau de neurones ne bat la marche aléatoire. Leurs prévisions sont quasi constantes : écart-type de 0,06 % contre 1,3 % pour les rendements réels.

2. Lien entre XOM et XLE
- Les chocs des deux rendements ont une corrélation de 0,915 le même jour.
- Test de Granger de XLE vers XOM : p = 0,009 avec le test classique, mais p = 0,20 avec des erreurs-types robustes à l'hétéroscédasticité (HC3).
- Fonction de réponse impulsionnelle : un choc d'un écart-type sur XLE fait varier XOM de +1,63 % le jour même, de −0,08 % le lendemain, puis l'effet est nul.
- Décomposition de la variance (FEVD) : la part de XLE dans la variance de prévision de XOM vaut 83,7 % si XLE est placé en premier dans l'ordre de Cholesky, et 0,3 % si XOM est placé en premier.
- Cointégration des log-prix : Engle-Granger p = 0,037 ; Johansen, statistique de trace 14,73 pour des valeurs critiques de 13,43 à 10 % et 15,49 à 5 %. La relation n'est significative dans aucune des deux sous-périodes 2016-2019 et 2021-2024.
- Modèle à correction d'erreur (VECM) : la vitesse d'ajustement n'est significative ni pour XOM (p = 0,93) ni pour XLE (p = 0,16). La demi-vie d'un écart à l'équilibre est de 62,6 jours de bourse.

3. Volatilité (risque)
- Le modèle retenu est un GJR-GARCH(1,1) avec loi de Student : $\omega = 0{,}0094$, $\alpha = 0{,}043$, $\gamma = 0{,}042$ ($p = 0{,}004$), $\beta = 0{,}935$, $\nu = 7{,}47$ degrés de liberté.
- La loi de Student améliore la log-vraisemblance d'environ 37 points par rapport à la loi normale.
- Persistance ($\alpha + \beta + \gamma/2$) : 0,9993 sur 2016-2024 (demi-vie de 1 015 jours), mais 0,893 sur 2016-2019 et 0,996 sur 2021-2024.
- Pics de volatilité annualisée estimée : 107 % le 2020-03-19, 47 % le 2022-03-16 et 52 % le 2022-06-24.
- Après le modèle, l'effet ARCH résiduel passe de 441 à 14 ($p = 0{,}016$).

Contraintes pour ta réponse :
- n'utilise aucun chiffre qui ne figure pas ci-dessus ;
- signale clairement ce que ces résultats ne permettent **pas** de conclure.

Réponse du LLM

- **Modèle :** ChatGPT, agent GPT-6 (nom donné par l'étudiant)
- **Date :** 2026-11-08
- **Prompt :** `llm/prompts/02_vulgarisation.md`, envoyé dans une nouvelle conversation
- **Réponse :** intégrale, copiée sans retouche ci-dessous

Analyse statistique de l'action Exxon Mobil (XOM) et de l'ETF énergétique XLE (2016–2024)
Objectif : comprendre ce que les modèles statistiques nous apprennent sur les rendements, les relations entre XOM et XLE et les risques liés à l'investissement.
1. Peut-on prévoir le rendement de l'action XOM ?
Les résultats montrent qu'il est très difficile de prévoir précisément le rendement quotidien de

l'action Exxon Mobil. Le modèle statistique le plus fiable retenu est la marche aléatoire : concrètement, cela signifie que la meilleure estimation du rendement de demain est zéro. Autrement dit, les informations historiques sur les prix ne permettent pas d'anticiper de manière suffisamment fiable si l'action va monter ou baisser le lendemain.

D'autres modèles, notamment les réseaux de neurones LSTM et GRU, ont été testés. Cependant, leurs performances sont légèrement moins bonnes que celles de la marche aléatoire. De plus, leurs prévisions varient très peu par rapport aux fluctuations réellement observées. Cela signifie qu'ils ont tendance à lisser les mouvements du marché plutôt qu'à anticiper ses variations.

Ce qu'on peut en retenir : les modèles testés ne fournissent pas d'avantage prévisionnel fiable pour anticiper les rendements quotidiens de XOM. Il serait donc imprudent de les utiliser seuls pour prendre des décisions d'achat ou de vente à court terme.

2. XOM évolue-t-elle avec le secteur énergétique ?

Les rendements de XOM et de XLE présentent une corrélation très élevée de 0,915. Cela signifie que les deux actifs évoluent généralement dans la même direction le même jour. Cette relation est logique puisque XOM représente une composante importante de l'ETF XLE.

Toutefois, cette forte corrélation ne signifie pas que XLE permet nécessairement de prévoir les mouvements futurs de XOM. Le test statistique suggère initialement une influence de XLE sur XOM, mais cette influence devient non significative lorsqu'on utilise une méthode de calcul plus robuste aux variations du risque. L'effet observé semble donc insuffisant pour affirmer que XLE possède un véritable pouvoir prédictif.

Par ailleurs, les analyses montrent une possible relation de long terme entre les prix des deux actifs, mais les résultats restent fragiles : cette relation n'est pas confirmée de manière suffisamment solide par les différentes méthodes et disparaît lorsqu'on étudie séparément les périodes.

Ce qu'on peut en retenir : XOM est fortement liée à la dynamique du secteur énergétique. XLE peut donc servir d'indicateur du contexte sectoriel, mais les résultats ne prouvent pas qu'il constitue un outil fiable pour anticiper les rendements futurs de XOM.

3. Comment évolue le risque de l'action ?

L'analyse de la volatilité montre que le risque de XOM n'est pas constant. Il augmente pendant certaines périodes et reste élevé après les grands événements de marché.

Le modèle retenu, GJR-GARCH avec une distribution de Student, montre également que les mauvaises surprises sur le marché ont un effet plus important sur la volatilité que les bonnes surprises de même ampleur. Cela signifie que les baisses importantes peuvent entraîner une augmentation particulière de l'incertitude.

Les périodes de forte volatilité correspondent notamment aux perturbations observées en mars 2020 et aux tensions sur le marché énergétique en 2022. Les résultats montrent aussi que la volatilité est très persistante sur l'ensemble de la période étudiée : après un choc important, le risque estimé peut rester élevé pendant longtemps.

Le modèle améliore la prise en compte des variations du risque, mais il ne supprime pas complètement les effets de volatilité qui restent présents dans les données.

Ce qu'on peut en retenir : la gestion du risque doit être dynamique. Il ne suffit pas de considérer la volatilité comme une donnée fixe : elle peut augmenter fortement et rester élevée pendant une période prolongée.
4. Conclusion pour la direction financière : quelles décisions prendre ?
Cette étude permet de dégager trois enseignements importants :
- Prévision : les modèles testés ne permettent pas de prévoir efficacement les rendements quotidiens de XOM. Il faut éviter de construire une stratégie d'investissement reposant uniquement sur ces prévisions.
- Exposition sectorielle : XOM évolue fortement avec le secteur énergétique. Le suivi de XLE peut aider à comprendre l'environnement dans lequel évolue l'entreprise.
- Gestion du risque : la volatilité est variable, asymétrique et persistante. Le suivi régulier du risque est donc essentiel pour adapter les décisions financières.
Il faut néanmoins souligner les limites de cette étude : elle ne permet pas de prévoir le cours futur de XOM, de garantir un rendement positif, de déterminer le meilleur moment pour acheter ou vendre, ni de démontrer une relation de causalité solide entre XLE et XOM. Elle ne permet pas non plus de conclure que les résultats resteront identiques à l'avenir.

En définitive, la principale valeur de cette étude n'est pas de prédire le marché, mais de mieux comprendre ses comportements et ses risques. Pour un directeur financier, elle constitue un outil d'aide à la décision et de gestion de l'exposition au risque, et non un système de prévision ou une garantie de performance.

C.3 Tâche 3 : essai envoyé sans données

Réponse du LLM

- **Modèle :** ChatGPT, agent GPT-6 (nom donné par l'étudiant)
- **Date :** 2026-11-08
- **Prompt :** `llm/prompts/03_recommandations.md`, envoyé **avec les champs « [À REMPLIR] » encore vides**, c'est-à-dire avant la phase 6. Le LLM n'avait aucune prévision ni aucun intervalle.
- **Statut :** essai conservé à titre documentaire. La version qui fera foi sera `03_recommandations_<modele>_<date>.md`, envoyée avec les résultats de la phase 6.
- **Réponse :** intégrale, copiée sans retouche ci-dessous.

Analyse et recommandations d'investissement simulées – Exxon Mobil (XOM)
Statut : exercice académique – simulation uniquement

Les données nécessaires à l'analyse ne sont pas encore renseignées. Les prévisions, les intervalles de confiance, la volatilité et les résultats des tests statistiques sont remplacés par des champs à compléter.

Il serait incorrect de formuler une recommandation d'achat ou de vente sans connaître ces résultats. Voici néanmoins la grille d'analyse et les recommandations conditionnelles à appliquer.
1. Interprétation des prévisions
Le modèle ARIMA(0,1,0) + GJR-GARCH-t combine deux approches :
- ARIMA(0,1,0) : sert de référence pour prévoir l'évolution du prix à partir de la dernière

observation, sans supposer une tendance systématique.
- GJR-GARCH-t : estime la volatilité future en tenant compte de l'évolution passée des variations de prix et de la possibilité que les mauvaises nouvelles aient un effet différent des bonnes nouvelles.
Les prévisions à 1, 5 et 10 jours donnent une indication de l'évolution possible du cours, tandis que les intervalles à 95 % permettent d'apprécier l'incertitude associée.

Il faut toutefois rappeler qu'un intervalle à 95 % n'est pas une garantie que le prix restera dans cette fourchette.
2. Recommandations d'investissement simulées
Scénario 1 – Achat à court terme
Condition : si la prévision à 1 jour indique une évolution favorable et que l'incertitude reste relativement limitée.

Une position acheteuse pourrait être envisagée dans le cadre de cette simulation, avec un horizon très court.

Limites et risques :
- Le modèle ne garantit pas que le mouvement prévu se réalisera.
- Les coûts de transaction peuvent réduire, voire annuler, un éventuel gain.
- L'horizon d'un jour est particulièrement sensible aux événements imprévus.
- L'intervalle à 95 % rappelle que plusieurs évolutions restent possibles.
- Un changement brutal des conditions du marché peut rendre la prévision rapidement obsolète.
Scénario 2 – Position à moyen terme
Condition : si les prévisions à 5 jours confirment une évolution favorable et que la volatilité prévue reste maîtrisée.

Une position acheteuse pourrait être étudiée dans cette simulation, sous réserve de la cohérence des résultats statistiques.

Limites et risques :
- L'incertitude augmente généralement avec l'horizon de prévision.
- Les erreurs de prévision peuvent s'accumuler.
- Les frais de transaction et les éventuels coûts de détention doivent être pris en compte.
- Le modèle peut mal réagir à un changement de régime économique ou financier.
Scénario 3 – Prudence à horizon de 10 jours
Condition : si les intervalles de prévision à 10 jours sont particulièrement larges ou si la volatilité prévue est élevée.

Dans ce cas, conserver une position neutre dans la simulation ou attendre de nouvelles observations serait plus prudent qu'une décision d'achat fondée uniquement sur la prévision ponctuelle.

Limites et risques :
- Une prévision à 10 jours comporte davantage d'incertitude.
- Les intervalles à 95 % ne couvrent pas nécessairement les événements extrêmes.
- Les changements de politique monétaire, les tensions géopolitiques et les chocs pétroliers peuvent modifier les conditions du marché.

- Le modèle repose sur des relations statistiques historiques qui peuvent ne plus être représentatives.

3. Évaluation de la qualité des prévisions

Les indicateurs RMSE, MAE et le test de Diebold-Mariano permettent d'évaluer la qualité des prévisions.

Indicateur · Interprétation

RMSE · Mesure l'importance des erreurs, en pénalisant davantage les grandes erreurs.

MAE · Mesure l'erreur absolue moyenne en dollars.

Diebold-Mariano · Permet de comparer statistiquement les performances prédictives de deux modèles.

La comparaison avec la marche aléatoire est particulièrement importante : si le modèle ARIMA-GARCH ne fait pas significativement mieux que cette référence, il n'existe pas de justification statistique suffisante pour lui accorder un avantage prédictif.

4. Ce que les modèles ne peuvent pas prévoir

Même avec de bonnes performances historiques, ARIMA et GJR-GARCH ne peuvent pas prévoir de manière fiable :

- Les décisions inattendues de l'OPEP et de l'OPEP+.
- Les guerres et les crises géopolitiques.
- Les catastrophes naturelles et les incidents majeurs dans les installations pétrolières.
- Les annonces financières inattendues d'Exxon Mobil.
- Les changements réglementaires et fiscaux.
- Les mouvements imprévus des taux d'intérêt et des marchés financiers.
- Les changements structurels de l'offre et de la demande de pétrole.

Ces événements peuvent provoquer des variations importantes que les données historiques ne permettent pas nécessairement d'anticiper.

5. Conclusion générale

Dans cet exercice, les modèles ARIMA(0,1,0) et GJR-GARCH-t doivent être considérés comme des outils d'aide à l'analyse statistique et non comme des systèmes autonomes de décision d'investissement.

La décision simulée doit tenir compte simultanément de la direction des prévisions, de leur incertitude, de la volatilité anticipée et de la comparaison avec la marche aléatoire.

Une prévision favorable ne constitue pas, à elle seule, un signal d'achat. De même, une prévision défavorable ne constitue pas automatiquement un signal de vente.

C.4 Tâche 3 : recommandations simulées

Prompt envoyé

Tu es analyste. À partir des résultats ci-dessous sur l'action Exxon Mobil (XOM), formule des recommandations d'investissement **simulées** : c'est un exercice académique, pas un conseil réel.

1. Modèle et prévision depuis le dernier jour observé

Le modèle retenu est une marche aléatoire pour le prix, ARIMA(0,1,0) sur le log-prix, combinée à un GJR-GARCH(1,1) avec loi de Student pour la volatilité. Il est estimé sur les données journalières du 2016-01-04 au 2025-12-31.

Dernier prix observé, le 2025-12-31 : **117,97 $**.

Horizon	Prévision du prix	Intervalle à 95 %	Volatilité prévue (annualisée)
1 jour	117,97 $	[115,29 ; 120,65] $	17,8 %
5 jours	117,97 $	[112,17 ; 123,96] $	18,1 %
10 jours	117,97 $	[109,87 ; 126,37] $	18,4 %

2. Évaluation sur l'année 2025 (période de test non utilisée pour estimer les modèles)

Les prévisions ont été faites depuis chacun des 252 jours de 2025. Les modèles classiques ont été ré-estimés tous les 20 jours. Sur cette période, XOM est passée de 100,69 $ à 117,97 $.

Erreurs de prévision du prix, en dollars :

Modèle	RMSE h = 1	MAE h = 1	RMSE h = 5	MAE h = 5	RMSE h = 10	MAE h = 10
Marche aléatoire	1,560	1,170	3,617	2,762	4,650	3,487
VAR(1) XOM-XLE	1,561	1,166	3,616	2,741	4,628	3,465
VECM XOM-XLE	1,560	1,170	3,618	2,763	4,652	3,489
ARIMA(3,1,2)	1,569	1,175	3,620	2,764	4,657	3,495
LSTM	1,558	1,171	3,672	2,810	4,867	3,668
GRU	1,558	1,170	3,630	2,771	4,770	3,590
Hybride ARIMA + LSTM	1,569	1,175	3,670	2,807	4,866	3,666

Test de Diebold-Mariano contre la marche aléatoire (perte quadratique, correction de Harvey-Leybourne-Newbold) :
- aucun modèle n'est significativement meilleur que la marche aléatoire, à aucun horizon de 1 à 10 jours ;
- le VAR(1) à 10 jours a p = 0,69 ;
- sont significativement moins bons à 10 jours : ARIMA(3,1,2) ($p < 0,001$), LSTM ($p = 0,011$), GRU ($p < 0,001$) et hybride ($p = 0,008$).

Intervalles à 95 % à 1 jour sur 2025 :
- modèles à variance constante : le prix réalisé est dans l'intervalle 98,0 % du temps (test binomial de couverture à 95 % : p = 0,028), largeur moyenne 7,46 $;
- GJR-GARCH-t : 94,8 % du temps (p = 0,885), largeur moyenne 6,27 $.

Prévision de la variance à 1 jour (perte QLIKE, plus faible = meilleure) : GJR-GARCH-t 1,732 ; variance constante 1,844. Diebold-Mariano : p = 0,075.

Exigences pour ta réponse
1. Pour chaque recommandation, **formule toi-même** les limites et les risques : risque de modèle, coûts de transaction, horizon, incertitude des intervalles, changement de régime.
2. N'utilise aucun chiffre absent de ce message.
3. Indique ce que ces modèles **ne peuvent pas** prévoir.

Réponse du LLM

- **Modèle :** ChatGPT, agent GPT-6 (nom donné par l'étudiant)
- **Date :** 2026-11-08
- **Prompt :** `llm/prompts/03_recommandations.md`, version remplie avec les résultats de la phase 6, envoyée dans une nouvelle conversation
- **Réponse :** intégrale, copiée sans retouche ci-dessous

Analyse et recommandations d'investissement simulées – Exxon Mobil (XOM)
Exercice académique – Novembre 2026
Aucun conseil financier réel

1. Synthèse de l'analyse

Les résultats statistiques conduisent à une conclusion importante : le prix de l'action Exxon Mobil est difficile à prévoir à court terme, et les modèles étudiés ne démontrent pas de capacité significative à anticiper son évolution mieux qu'une simple marche aléatoire.

Le modèle retenu, ARIMA(0,1,0) associé à un GJR-GARCH(1,1) avec loi de Student, prévoit un prix constant de 117,97 $ aux trois horizons étudiés.

Cela ne signifie pas que le cours restera effectivement à ce niveau. Cela signifie que le modèle ne dispose pas d'informations statistiques suffisamment solides pour prévoir une hausse ou une baisse moyenne.

En revanche, le modèle GJR-GARCH-t apporte une information complémentaire sur le risque : il estime l'ampleur potentielle des fluctuations du cours et adapte les intervalles de prévision à l'évolution de la volatilité.

2. Recommandations d'investissement simulées

Recommandation 1 – Conserver l'action (HOLD)
Recommandation privilégiée
Justification :

La marche aléatoire constitue une référence difficile à dépasser. Aucun modèle testé n'a démontré une supériorité statistiquement significative sur cette référence.

Par conséquent, les résultats ne fournissent pas de justification statistique solide pour vendre immédiatement l'action ou renforcer une position dans l'espoir d'une hausse à court terme.

Pour un investisseur qui détient déjà XOM, une stratégie de conservation peut donc être retenue dans cette simulation.

Limites et risques :
- Risque de modèle : la marche aléatoire suppose implicitement que les variations futures ne peuvent pas être anticipées à partir des informations historiques exploitées.
- Incertitude : l'intervalle à 95 % à 10 jours s'étend de 109,87 $ à 126,37 $, ce qui représente une dispersion importante autour de la prévision centrale.
- Changement de régime : une évolution brutale du marché pétrolier ou de l'environnement économique pourrait rendre les paramètres historiques moins représentatifs.
- Coûts de transaction : conserver une position évite de multiplier les achats et les ventes, mais ne supprime pas les coûts de détention éventuels.

Recommandation 2 – Éviter les achats spéculatifs à très court terme (BUY : prudence)
Justification :

Le modèle ne prévoit aucune progression du prix à 1, 5 ou 10 jours.

De plus, les résultats du test de Diebold-Mariano montrent qu'aucun modèle étudié ne surpasse significativement la marche aléatoire.

Il serait donc difficile de justifier un achat spéculatif à court terme sur la seule base de ces prévisions.

Un achat pourrait éventuellement être envisagé dans une stratégie de détention plus longue, mais il nécessiterait d'autres éléments d'analyse, notamment fondamentaux.

Limites et risques :
- Les prévisions ne garantissent pas que le cours restera proche de 117,97 $.
- Les intervalles à 95 % ne couvrent pas tous les scénarios possibles : des mouvements plus importants restent envisageables.
- Les frais de transaction peuvent réduire la rentabilité d'une stratégie d'achats et de ventes fréquents.
- Le modèle ne tient pas compte des changements soudains de comportement des investisseurs.

Recommandation 3 – Utiliser le GJR-GARCH-t pour gérer le risque
Intérêt statistique démontré
Justification :

Le GJR-GARCH-t présente de meilleurs résultats pour la modélisation de la volatilité que le modèle à variance constante.

Deux observations soutiennent ce choix :
- Sa couverture empirique des intervalles à 95 % est de 94,8 %, avec une valeur p de 0,885 au test de couverture.
- Sa perte QLIKE est de 1,732, contre 1,844 pour le modèle à variance constante.

Cela indique que le GJR-GARCH-t constitue un outil intéressant pour évaluer le risque associé à l'action.

Il faut néanmoins rester prudent : le test de Diebold-Mariano donne une valeur p de 0,075 pour la comparaison des prévisions de variance. L'amélioration observée n'est donc pas statistiquement significative au seuil habituel de 5 %.

Limites et risques :
- Le modèle estime la volatilité, mais ne prédit pas avec certitude la direction du cours.
- Les intervalles reposent sur des hypothèses statistiques qui peuvent devenir moins adaptées lors de crises.
- La loi de Student permet de mieux représenter certaines fluctuations extrêmes, mais ne garantit pas la prise en compte de tous les événements exceptionnels.
- Une mauvaise estimation de la volatilité peut conduire à une évaluation insuffisante du risque réel.

Recommandation 4 – Ne pas utiliser les modèles complexes comme argument principal

d’achat ou de vente
Justification :

Les modèles LSTM, GRU et hybride ARIMA-LSTM n’ont pas apporté d’amélioration significative par rapport à la marche aléatoire.

À 10 jours, ils présentent même des performances statistiquement moins bonnes :
Modèle · Résultat du test DM
LSTM · p = 0,011
GRU · p inférieur à 0,001
Hybride ARIMA-LSTM · p = 0,008

Ces résultats montrent qu’une architecture plus complexe ne garantit pas une meilleure prévision financière.

Il serait donc préférable de privilégier un modèle simple et interprétable plutôt que de choisir automatiquement le modèle le plus sophistiqué.

Limites et risques :
- Les performances observées en 2025 ne garantissent pas les performances futures.
- Les modèles complexes peuvent être sensibles aux données utilisées pour leur apprentissage.
- Un changement de régime économique peut dégrader leurs performances.
- Les coûts de transaction et les contraintes d’exécution ne sont pas intégrés dans les erreurs statistiques présentées.

3. Ce que les modèles ne peuvent pas prévoir
Il est essentiel de distinguer la prévision statistique de la réalité économique et financière.

Les modèles étudiés ne permettent pas de prévoir avec certitude :
Élément · Pourquoi ?
Les décisions de l’OPEP · Elles dépendent de décisions économiques et politiques.
Les conflits géopolitiques · Leur apparition et leurs conséquences sont difficiles à anticiper statistiquement.
Les variations futures du prix du pétrole · Elles dépendent de l’offre, de la demande et des événements internationaux.
Les résultats financiers d’Exxon Mobil · Les modèles de prix étudiés n’intègrent pas directement les futurs résultats de l’entreprise.
Les annonces de dividendes · Elles dépendent des décisions de l’entreprise.
Les décisions des banques centrales · Elles peuvent modifier les conditions financières et les comportements des investisseurs.
Les crises financières · Leur déclenchement et leur ampleur ne sont pas prévisibles avec fiabilité par ces modèles.
Les réactions des investisseurs · Les comportements collectifs peuvent évoluer rapidement.

En particulier, un intervalle de confiance à 95 % ne signifie pas qu’il existe une garantie de 95 % que le prix futur restera dans cet intervalle. Il s’agit d’une mesure statistique conditionnelle aux hypothèses du modèle et à sa méthode de construction.
4. Tableau récapitulatif des décisions simulées
Stratégie · Recommandation · Justification
Investisseur détenant déjà XOM · HOLD · Absence de signal statistique significatif de vente

ou d’achat.
Nouvel investisseur à court terme · Prudence · Absence d’avantage prédictif démontré.
Gestion du risque · Utiliser GJR-GARCH-t · Meilleure couverture empirique et meilleure perte QLIKE observées.
Choix du modèle · Privilégier la marche aléatoire · Simplicité et performances compétitives.
Modèles Deep Learning · Ne pas les privilégier · Performances inférieures à 10 jours.

5. Conclusion générale

L’étude de l’action Exxon Mobil montre que la prévision des prix financiers demeure un exercice particulièrement incertain, même avec des modèles statistiques et des architectures d’intelligence artificielle avancées.

La marche aléatoire constitue ici une référence pertinente, puisqu’aucun des modèles concurrents ne démontre une amélioration statistiquement significative de la prévision du prix.

Le GJR-GARCH-t présente néanmoins un intérêt complémentaire pour la mesure de la volatilité et l’évaluation des risques.

La recommandation simulée finale est donc de conserver une position existante sur XOM, d’éviter les décisions spéculatives fondées uniquement sur les prévisions à court terme et d’utiliser le GJR-GARCH-t comme outil complémentaire de gestion du risque.

Cette recommandation reste conditionnelle : elle ne repose ni sur une valorisation fondamentale de l’entreprise, ni sur une analyse de ses dividendes, de sa situation financière ou des perspectives du secteur énergétique.

Enseignement principal de l’étude : en finance, un modèle performant pour mesurer le risque n’est pas nécessairement performant pour prévoir le prix. Et un modèle complexe n’est pas automatiquement meilleur qu’un modèle simple.

Annexe D. Comparaison détaillée entre notre interprétation et celle du LLM

Auteurs : Aziz Bellaaj, Mohamed Yassine Khiari
Date : 2026-11-08

Sources comparées :

- notre interprétation, rédigée avant le LLM : `interpretation_personnelle.md` ;
- les réponses du LLM (ChatGPT, agent GPT-6) : `responses/01_hypotheses_chatgpt-gpt6_2026-11-08.md` et `responses/02_vulgarisation_chatgpt-gpt6_2026-11-08.md`.

Prompt 1 — Hypothèses de modèles

Thème	Notre interprétation	LLM	Verdict	Justification
Modèle de la moyenne	ARIMA(0,1,0) sur le log-prix	ARIMA(0,0,0) sur les rendements	**Convergence**	Le rendement est le log-prix différencié une fois : les deux écritures désignent le même modèle.
Volatilité	GJR-GARCH(1,1) avec loi de Student	GARCH(1,1)-t en priorité, GJR et EGARCH à tester	**Convergence**	Nos tests confirment l'effet de levier : γ est significatif ($p = 0{,}004$).
Lien de long terme entre XOM et XLE	Cointégration testée (Engle-Granger, Johansen) : relation fragile	Aucun test de cointégration proposé	**Oubli du LLM**	Les deux log-prix sont I(1), et le LLM le sait. C'est précisément le cas où il faut tester la cointégration.
Rendement passé de XLE pour prévoir XOM	Granger robuste : $p = 0{,}20$, le passé de XLE n'améliore pas la prévision	Propose un ARMAX avec le rendement retardé de XLE	**Divergence**	Une idée raisonnable à tester, mais nos résultats la rejettent. Le LLM ne pouvait pas le savoir sans nos tests.

Prompt 2 — Vulgarisation

Thème	Notre interprétation	LLM	Verdict	Justification
Persistance de la volatilité	0,999, gonflée par la rupture de 2020 ; 0,893 sur 2016–2019	« Très persistante : le risque peut rester élevé longtemps »	**Simplification excessive**	Le LLM omet la valeur de 2016–2019 alors qu'elle figurait dans le prompt. Il prend la persistance à la lettre (erreur 7 de la grille).
Explication des pics de volatilité	On ne donne que des dates (2020-03-19, 2022-06-24)	« Tensions sur le marché énergétique en 2022 »	**Explication ajoutée par le LLM**	Cette cause ne figurait pas dans le prompt : le LLM l'a ajoutée lui-même (erreur 5 de la grille). Elle doit être vérifiée par une source, voir `docs/sources.md`.
Corrélation de 0,915	Corrélation des **chocs** (résidus du VAR) le même jour	« Les **rendements** ont une corrélation de 0,915 »	**Imprécision**	Le LLM change le sens du chiffre fourni : il s'agit des chocs, pas des rendements bruts. La valeur est proche, mais ce n'est pas la même grandeur.

Thème	Notre interprétation	LLM	Verdict	Justification
FEVD	84 % ou 0,3 % selon l'ordre de Cholesky : on ne peut pas dire qui entraîne qui	Non mentionnée	**Oubli du LLM**	Le résultat le plus piégeux du prompt est passé sous silence. Le décideur ne saura pas que la part de XLE n'est pas identifiable.
Test de Granger	Prédictibilité incrémentale, non robuste (HC3, p = 0,20)	« Le test suggère initialement une **influence** de XLE sur XOM »	**Vocabulaire causal**	Granger mesure une prédictibilité, pas une influence (erreur 2 de la grille). L'erreur reste légère, car le LLM écrit ensuite qu'il n'y a pas de « relation de causalité solide ».

Prompt 3 — Essai sans données (03a)

Le prompt a été envoyé par erreur avant la phase 6, avec les champs de données encore vides. L'essai est conservé, car il révèle le comportement du LLM quand il n'a aucun chiffre.

Thème	Notre interprétation	LLM	Verdict	Justification
Données absentes	—	« Il serait incorrect de formuler une recommandation sans connaître ces résultats »	**Bon comportement**	Le LLM n'invente aucun chiffre et signale que les données manquent.
Achat si la prévision est « favorable »	La marche aléatoire prévoit le même prix chaque jour (rendement prévu nul)	Scénarios 1 et 2 : acheter si la prévision à 1 ou 5 jours indique une évolution favorable	**Erreur de raisonnement**	Avec ARIMA(0,1,0), la prévision ponctuelle ne peut jamais être « favorable » : ces scénarios ne peuvent pas se produire. Le LLM décrit le modèle correctement, mais n'en tire pas la conséquence.
« Direction des prévisions »	Le GARCH prévoit l'amplitude, pas le sens (§3.3)	La décision doit tenir compte de « la direction des prévisions » et de la volatilité	**Erreur 3 de la grille**	Aucun des deux modèles ne fournit de direction. Seule l'amplitude du risque est prévisible.

Prompt 3 — Recommandations avec les résultats de la phase 6

Thème	Notre interprétation	LLM	Verdict	Justification
Chiffres cités	Valeurs des tableaux tab36 à tab39	Tous les chiffres cités figurent dans le prompt	**Bon comportement**	Aucune p-value ni statistique inventée (erreur 1 de la grille évitée).
Lecture des tests	Diebold-Mariano : aucun modèle meilleur que la marche aléatoire ; variance : p = 0,075, non significatif à 5 %	Mêmes conclusions, y compris « pas statistiquement significative au seuil de 5 % » pour p = 0,075	**Convergence**	Le LLM ne surinterprète pas le meilleur QLIKE du GARCH, qui n'est significatif qu'à 10 %.
Direction du prix	Le GARCH prévoit l'amplitude, pas le sens (§3.3)	« Le modèle estime la volatilité, mais ne prédit pas **avec certitude** la direction du cours »	**Erreur 3 de la grille**	« Avec certitude » laisse croire que le GARCH prédit un peu la direction. Il ne la prédit pas du tout.
Recommandation HOLD	La marche aléatoire ne donne aucun	« Conserver l'action », car il n'y a « pas de	**Raisonnement non fondé**	L'absence de signal ne favorise aucune

Thème	Notre interprétation	LLM	Verdict	Justification
	signal, ni pour vendre, ni pour garder	signal statistique significatif de vente »		décision : garder l'action est aussi un pari. Le choix dépend du risque que l'investisseur accepte. La recommandation cohérente avec nos résultats serait de dimensionner la position avec la volatilité prévue par le GARCH.
Vocabulaire	Intervalle de **prévision** à 95 % (sur un prix futur)	« Intervalle de **confiance** à 95 % »	**Vocabulaire statistique**	Un intervalle de confiance porte sur un paramètre, un intervalle de prévision sur une valeur future.

Bilan

Verdict	Nombre
Convergences et bons comportements	5
Divergence	1
Oublis du LLM	2
Simplification, imprécision ou ajout non fondé	3
Erreurs de raisonnement	2
GARCH présenté comme prévoyant la direction (erreur 3)	2
Vocabulaire causal ou statistique	2

Ce que le LLM fait bien. Sur les **faits principaux**, il converge avec notre interprétation : marche aléatoire pour la moyenne, GARCH avec loi de Student et effet de levier pour la variance, aucun avantage des réseaux de neurones. Il n'invente aucune p-value, signale l'absence de données (essai 03a) et lit correctement les tests quand on les lui fournit.

Ses erreurs sont plus subtiles :

- il **oublie** les résultats qui nuancent, comme la cointégration ou la dépendance de la FEVD à l'ordre ;
- il **simplifie** la persistance de la volatilité ;
- il **ajoute** des explications qu'on ne lui a pas fournies ;
- il **attribue au GARCH une capacité à prévoir la direction**, même atténuée (« avec certitude ») ;
- il **tire des recommandations que les résultats ne justifient pas** : achat si la prévision est « favorable », alors qu'une marche aléatoire est toujours plate ; HOLD faute de signal de vente.

Conclusion. Le LLM est un bon outil de reformulation quand on lui donne des résultats vérifiés. En revanche, il ne contrôle pas la cohérence entre le modèle et la décision qu'il en tire. Un décideur qui lirait ses réponses seules aurait une image trop simple de la volatilité et du lien entre XOM et XLE, et pourrait croire que nos modèles justifient une décision d'investissement.